BỘ CÔNG THƯƠNG
TRƯỜNG ĐẠI HỌC CÔNG NGHIỆP TP. HỒ CHÍ MINH
KHOA CÔNG NGHỆ THÔNG TIN



PHẠM HOÀNG PHÁT – 22703861

THÂN TRỌNG TÍNH – 22665711

BÁO CÁO GIỮA KỲ
KHÓA LUẬN TỐT NGHIỆP

XÂY DỰNG HỆ THỐNG PHÁT HIỆN, SINH MÔ TẢ VÀ TRUY VẤN SỰ KIỆN ÂM THANH MÔI TRƯỜNG DỰA TRÊN RAG

Ngành: Khoa học dữ liệu

Giảng viên hướng dẫn: TS. Huỳnh Công Bằng

THÀNH PHỐ HỒ CHÍ MINH, THÁNG 10 NĂM 2026

BỘ CÔNG THƯƠNG
TRƯỜNG ĐẠI HỌC CÔNG NGHIỆP TP. HỒ CHÍ MINH
KHOA CÔNG NGHỆ THÔNG TIN



Phạm Hoàng Phát – 22703861

Thân Trọng Tính – 22665711

BÁO CÁO GIỮA KỲ KHÓA LUẬN TỐT NGHIỆP

XÂY DỰNG HỆ THỐNG PHÁT HIỆN, SINH MÔ TẢ VÀ TRUY VẤN SỰ KIỆN ÂM THANH MÔI TRƯỜNG DỰA TRÊN RAG

Ngành: Khoa học dữ liệu

Giảng viên hướng dẫn: TS. Huỳnh Công Bằng

THÀNH PHỐ HỒ CHÍ MINH, THÁNG 10 NĂM 2026

INDUSTRIAL UNIVERSITY OF HO CHI MINH CITY
FACULTY OF INFORMATION TECHNOLOGY



Pham Hoang Phat – 22703861

Than Trong Tinh – 22665711

MID-TERM GRADUATION THESIS REPORT

Grounded Environmental Sound Event Detection, Captioning, and RAG-based Retrieval

Major: Data Science

Supervisor: Dr. Huynh Cong Bang

HO CHI MINH CITY – OCTOBER 2026

ABSTRACT

Title: Grounded Environmental Sound Event Detection, Captioning, and RAG-based Retrieval

Outdoor noise monitoring needs to know which sound sources occur, when, and for how long. This mid-term report presents an end-to-end system that detects environmental sound events with temporal localization, captions recordings using only the detected event timeline, and answers natural-language questions over recording history with Retrieval-Augmented Generation (RAG), citing recordings and time spans as evidence.

The system uses two public datasets from the same authors: DataSEC (5,048 clips) and DataSED (717 recordings, 21 polyphonic classes). A three-tier deduplication audit found shared source recordings, so 11 DataSEC clips (0.22%) were excluded before pre-training and all splits were frozen by hash. Every choice was made on the development set and committed before the test set was evaluated once.

Additional pre-training on DataSEC did not improve event-based F1 over AudioSet pre-training (paired difference −0.003, 95% CI [−0.025, +0.020]). Sound event detection (SED) errors lie mainly in boundaries and missed events. The locked system reaches event-based macro-F1 0.121 and micro-F1 0.164 [0.110, 0.224] on the annotated test set and is not shown to beat the previous generation. Grammar-constrained captioning removed hallucinated sources and context inference relative to the predicted timeline, at a cost in omissions that a coverage constraint removes. Hard filters kept every retrieved result consistent with the query, and no answer contained unsupported claims, but retrieval is bounded by SED recall. Remaining work: a systematic literature review, development-set analyses and the final thesis.

Keywords: sound event detection, environmental noise, grounded captioning, hallucination, retrieval-augmented generation, transfer learning, data leakage.

TÓM TẮT

Tên đề tài: Xây dựng hệ thống phát hiện, sinh mô tả và truy vấn sự kiện âm thanh môi trường dựa trên RAG

Giám sát tiếng ồn môi trường cần biết nguồn âm nào xuất hiện, lúc nào và kéo dài bao lâu. Báo cáo giữa kỳ trình bày một hệ thống từ đầu đến cuối: phát hiện sự kiện âm thanh kèm thời gian, viết mô tả chỉ dựa trên các sự kiện đã phát hiện, và trả lời câu hỏi tự nhiên về lịch sử bản ghi bằng sinh tăng cường truy hồi (RAG), có nêu bản ghi và khoảng thời gian làm bằng chứng.

Nhóm dùng hai bộ dữ liệu công bố của cùng nhóm tác giả: DataSEC (5.048 đoạn) và DataSED (717 bản ghi, 21 lớp). Kiểm tra trùng lặp cho thấy hai bộ có chung bản ghi gốc, nên 11 đoạn DataSEC (0,22%) bị loại trước khi huấn luyện và các tập chia được khóa bằng mã băm. Mọi lựa chọn đều làm trên tập dev và được ghi lại trước khi đánh giá tập test một lần.

Huấn luyện thêm trên DataSEC không giúp event-F1 tốt hơn so với chỉ dùng mô hình tiền huấn luyện AudioSet (hiệu −0,003, khoảng tin cậy 95% [−0,025; +0,020]). Lỗi phát hiện sự kiện âm thanh (SED) chủ yếu là lệch biên và bỏ sót. Hệ thống được khóa đạt event-F1 macro 0,121 và micro 0,164 [0,110; 0,224] trên tập test có nhãn, và chưa được chứng minh tốt hơn thế hệ trước. Khi bắt mô tả bám sát danh sách sự kiện bằng ngữ pháp giải mã, mô tả không còn ảo giác nguồn âm hay suy diễn bối cảnh so với danh sách đó, đổi lại là bỏ sót nhiều hơn; thêm ràng buộc phải nhắc đủ các lớp thì hết bỏ sót. Bộ lọc cứng giữ mọi kết quả truy hồi đúng điều kiện và câu trả lời không có khẳng định thiếu bằng chứng, nhưng chất lượng truy hồi bị giới hạn bởi việc SED còn bỏ sót. Việc còn lại: tổng quan văn liệu có hệ thống, phân tích bổ sung trên tập dev và hoàn thiện khóa luận.

Từ khóa: phát hiện sự kiện âm thanh, tiếng ồn môi trường, mô tả có căn cứ, ảo giác, sinh tăng cường truy hồi, học chuyển giao, rò rỉ dữ liệu.

LỜI CẢM ƠN

Nhóm xin gửi lời cảm ơn chân thành đến TS. Huỳnh Công Bằng, người đã hướng dẫn, góp ý và định hướng cho nhóm trong suốt quá trình thực hiện khóa luận.

Nhóm cảm ơn quý thầy cô Khoa Công nghệ Thông tin, Trường Đại học Công nghiệp Thành phố Hồ Chí Minh đã truyền đạt kiến thức nền tảng để nhóm có thể thực hiện đề tài này.

Nhóm cũng cảm ơn các tác giả của hai bộ dữ liệu DataSEC và DataSED đã công bố dữ liệu mở, cùng cộng đồng nghiên cứu âm thanh đã chia sẻ mã nguồn và mô hình tiền huấn luyện mà nhóm sử dụng.

Cuối cùng, nhóm cảm ơn gia đình và bạn bè đã luôn động viên trong thời gian qua. Do thời gian có hạn, báo cáo giữa kỳ khó tránh khỏi thiếu sót; nhóm rất mong nhận được góp ý của quý thầy cô để hoàn thiện khóa luận.

NHẬN XÉT CỦA GIÁO VIÊN HƯỚNG DẪN

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

TP. Hồ Chí Minh, ngày .... tháng .... năm ……

CHỮ KÝ CỦA GIẢNG VIÊN

MỤC LỤC

DANH MỤC HÌNH ẢNH ix
DANH MỤC BẢNG BIỂU x
DANH MỤC CÁC THUẬT NGỮ VIẾT TẮT xi
CHƯƠNG 1 GIỚI THIỆU 1
1.1 Vì sao chọn đề tài 1
1.2 Bài toán đặt ra 2
1.3 Mục tiêu và câu hỏi nghiên cứu 2
1.4 Phạm vi và giới hạn 3
1.5 Đóng góp dự kiến 4
1.6 Bố cục báo cáo 4
CHƯƠNG 2 CƠ SỞ LÝ THUYẾT 5
2.1 Phát hiện sự kiện âm thanh 5
2.2 Cách đánh giá 5
2.3 Từ xác suất thành sự kiện 7
2.4 Học chuyển giao 7
2.5 Mô tả có bám sát sự kiện và ảo giác 8
2.6 Truy hồi và RAG 8
2.7 Vị trí của đề tài 9
CHƯƠNG 3 DỮ LIỆU 10
3.1 Hai bộ dữ liệu 10
3.2 Các lớp âm thanh 11
3.3 Quy trình chuẩn bị dữ liệu 11
3.4 Nhãn thiếu và độ nhất quán của nhãn 14
CHƯƠNG 4 PHƯƠNG PHÁP 16
4.1 Kiến trúc tổng thể 16
4.2 Mô hình phân loại trên DataSEC 17
4.3 Mô hình phát hiện sự kiện (SED) 18
4.4 Ghép xác suất thành sự kiện 19
4.5 Sinh mô tả bám sát sự kiện 20
4.6 Truy hồi và trả lời có bằng chứng 21
4.7 Cách đánh giá 22
CHƯƠNG 5 TRIỂN KHAI HỆ THỐNG 25
5.1 Tổ chức mã nguồn 25
5.2 Các dịch vụ 25
5.3 Chạy demo 26
5.4 Tái lập và kiểm thử 27
CHƯƠNG 6 KẾT QUẢ VÀ THẢO LUẬN 29

6.1 Mô hình phân loại DataSEC 29
6.2 RQ1: học thêm từ DataSEC có giúp không? 30
6.3 Mô hình SED tiến bộ ra sao? 31
6.3.1 Vì sao event-F1 của v1 thấp? 31
6.3.2 Từ v1 đến v2 32
6.3.3 Chọn hệ thống cuối và kết quả test 33
6.4 RQ2: mô tả có bám sát sự kiện không? 35
6.5 RQ3: truy hồi và câu trả lời có bằng chứng 36
6.6 Bộ phân tích câu hỏi và độ khớp khi phục vụ 38
6.7 Thảo luận và hạn chế 39
CHƯƠNG 7 TIẾN ĐỘ VÀ KẾ HOẠCH TIẾP THEO 41
7.1 Tiến độ so với kế hoạch 41
7.2 Mức độ đạt mục tiêu 42
7.3 Hạn chế 42
7.4 Kế hoạch giai đoạn tiếp theo 43
7.5 Kết luận giữa kỳ 43
TÀI LIỆU THAM KHẢO ..... a
PHỤ LỤC c
Phụ lục A. Hệ lớp và số sự kiện đa âm c
Phụ lục B. Artifact đã đóng băng ..... d
Phụ lục C. Kết quả theo lớp ..... d
NHẬT KÍ LÀM VIỆC ..... g

DANH MỤC HÌNH ẢNH

Hình 3.1 Quy trình chuẩn bị dữ liệu D0–D4 và các tệp đã khóa 12
Hình 4.1 Kiến trúc tổng thể của hệ thống 16
Hình 4.2 Sự kiện nhãn gốc và dự đoán của hệ f2 trên bản ghi dev S-0009 21
Hình 5.1 Giao diện demo: tải lên, dòng thời gian, bộ lọc từ câu hỏi và bằng chứng 26

DANH MỤC BẢNG BIỂU

Bảng 1.1 Ba câu hỏi nghiên cứu chính 3
Bảng 1.2 Bốn đóng góp dự kiến và mức bằng chứng ở giữa kỳ.....4
Bảng 3.1 Kết quả khử trùng lặp D3 và kiểm tra trùng giữa các tập D4.....13
Bảng 3.2 Hai bộ dữ liệu và tập chia đã khóa 14
Bảng 4.1 Các mã gọi tắt của mô hình và ứng viên SED.....17
Bảng 4.2 Bốn điều kiện thời gian giữa sự kiện a và b 22
Bảng 6.1 Kết quả mô hình phân loại DataSEC trên tập test 30
Bảng 6.2 Kết quả RQ1: công thức v1 (test all) và công thức v2 (test annotated) 31
Bảng 6.3 Xếp hạng 11 ứng viên trên dev và kết quả test annotated (một lần) 33
Bảng 6.4 Tiến triển SED v1 → v2 → f2 trên test annotated 34
Bảng 6.5 Mức bám sát sự kiện của mô tả trên test (hệ f2, 142 bản ghi).....35
Bảng 6.6 RQ3 trên test với bộ lọc gold: nDCG@10, Recall@10 và độ đúng bộ lọc 37
Bảng 6.7 Đánh giá bộ phân tích câu hỏi thành bộ lọc 38
Bảng 7.1 Kế hoạch và tiến độ thực tế tại mốc 03/10/2026 41
Bảng 7.2 Kế hoạch giai đoạn tiếp theo 43

DANH MỤC CÁC THUẬT NGỮ VIẾT TẮT

Từ viết tắt	Từ đầy đủ	Nghĩa
AAC	Automated Audio Captioning	Mô tả âm thanh tự động
ADR	Architecture Decision Record	Bản ghi quyết định kiến trúc
API	Application Programming Interface	Giao diện lập trình ứng dụng
BiGRU	Bidirectional Gated Recurrent Unit	Mạng hồi quy có cổng hai chiều
CI	Continuous Integration	Tích hợp liên tục
CNN	Convolutional Neural Network	Mạng nơ-ron tích chập
CPU	Central Processing Unit	Bộ xử lý trung tâm
CRNN	Convolutional Recurrent Neural Network	Mạng nơ-ron tích chập hồi quy
DCASE	Detection and Classification of Acoustic Scenes and Events	Chuỗi thử thách phát hiện và phân loại cảnh, sự kiện âm thanh
ECE	Expected Calibration Error	Sai số hiệu chuẩn kỳ vọng
GPU	Graphics Processing Unit	Bộ xử lý đồ họa
HNSW	Hierarchical Navigable Small World	Chỉ mục đồ thị cho tìm kiếm vector gần đúng
JSON	JavaScript Object Notation	Định dạng dữ liệu có cấu trúc
MFCC	Mel-Frequency Cepstral Coefficients	Hệ số cepstral thang mel
MRR	Mean Reciprocal Rank	Hạng nghịch đảo trung bình
nDCG	normalized Discounted Cumulative Gain	Lợi ích tích lũy chiết khấu chuẩn hóa
PANNs	Pretrained Audio Neural Networks	Mạng nơ-ron âm thanh tiền huấn luyện
PSDS	Polyphonic Sound Detection Score	Điểm phát hiện âm thanh đa âm
RAG	Retrieval-Augmented Generation	Sinh tăng cường truy hồi
RQ	Research Question	Câu hỏi nghiên cứu
SEBB	Sound Event Bounding Boxes	Hộp bao sự kiện âm thanh
SED	Sound Event Detection	Phát hiện sự kiện âm thanh
SQL	Structured Query Language	Ngôn ngữ truy vấn có cấu trúc

CHƯƠNG 1 GIỚI THIỆU

1.1 Vì sao chọn đề tài

Giám sát tiếng ồn ngoài trời thường chỉ dựa vào mức ồn trung bình. Con số này cho biết khu vực ồn đến đâu, nhưng không cho biết tiếng ồn đến từ nguồn nào, xuất hiện lúc nào và kéo dài bao lâu. Hai đêm có cùng mức ồn có thể do xe cộ hoặc do công trường, và mỗi trường hợp cần cách xử lý khác nhau. Vì vậy, nhóm quan tâm đến bài toán phát hiện sự kiện âm thanh (Sound Event Detection – SED): trong một bản ghi dài, xác định nguồn âm nào xuất hiện, bắt đầu (onset) và kết thúc (offset) lúc nào [11].

Bài toán này khó hơn việc phân loại một đoạn âm thanh đã cắt sẵn, vì ba lý do. Thứ nhất, nhiều nguồn âm có thể vang lên cùng lúc (đa âm, polyphonic) [11]. Thứ hai, dữ liệu có đánh dấu chính xác thời điểm (nhãn mạnh) tốn công làm nên thường ít, còn nhãn yếu chỉ cho biết lớp nào có mặt trong bản ghi [11]. Thứ ba, khi kết quả phát hiện được viết lại thành câu văn cho người đọc, mô hình ngôn ngữ dễ viết ra những điều không có trong dữ liệu đầu vào. Hiện tượng này gọi là ảo giác (hallucination) [7].

Nhóm dùng hai bộ dữ liệu công bố năm 2025 của cùng một nhóm tác giả: DataSEC gồm các đoạn âm thanh rời để phân loại, và DataSED gồm các bản ghi dài có đánh dấu thời gian [6]. Hai bộ dữ liệu cùng miền nên có thể hỗ trợ nhau (học chuyển giao), nhưng cũng có nguy cơ chứa cùng một bản ghi gốc. Nếu không kiểm soát, mô hình sẽ vô tình được huấn luyện trên chính dữ liệu dùng để kiểm tra.

Từ đó, đề tài xây dựng một hệ thống khép kín gồm bốn bước: nhận bản ghi và phát hiện sự kiện; viết mô tả chỉ dựa trên các sự kiện đã phát hiện; lưu sự kiện có cấu trúc; và trả lời câu hỏi về lịch sử bằng kỹ thuật sinh tăng cường truy hồi (Retrieval-Augmented Generation – RAG). RAG là cách cho mô hình ngôn ngữ tra cứu một kho

dữ liệu bên ngoài trước khi trả lời [9]. Mỗi câu trả lời phải nêu được bản ghi và khoảng thời gian làm bằng chứng.

1.2 Bài toán đặt ra

Với một bản ghi âm liên tục $x(t)$, hệ thống cần cho ba đầu ra liên quan với nhau. Đầu ra thứ nhất là danh sách sự kiện (dòng thời gian):

$$E = \{(c_i,\ t_i^{on},\ t_i^{off},\ s_i)\}_{i=1}^{N} \tag{1.1}$$

trong đó c_i là lớp nguồn âm, $t_i^{on} < t_i^{off}$ là thời điểm bắt đầu và kết thúc (giây), $s_i \in [0,1]$ là độ tin cậy, và các sự kiện được phép chồng nhau. Đầu ra thứ hai là một đoạn mô tả y chỉ được viết từ E, sao cho mọi nguồn âm được nhắc đến đều có trong E:

$$\text{mention}(y) \subseteq \{\, c_i : (c_i, t_i^{on}, t_i^{off}, s_i) \in E \,\} \tag{1.2}$$

Đầu ra thứ ba là câu trả lời cho một câu hỏi tự nhiên về lịch sử các bản ghi, kèm bằng chứng dạng (mã bản ghi, khoảng thời gian).

Điều kiện (1.2) giúp phân biệt đề tài với việc viết mô tả âm thanh tự do, vì máy có thể kiểm tra được điều kiện này. Tuy nhiên điều kiện chỉ bảo đảm mô tả **khớp với danh sách sự kiện mà hệ thống dự đoán**, chứ không bảo đảm khớp với âm thanh thật: nếu bước phát hiện sai thì mô tả cũng sai theo. Nhóm luôn tách riêng hai mức đúng này khi đánh giá (Chương 4 và 6).

1.3 Mục tiêu và câu hỏi nghiên cứu

Mục tiêu chung là dựng một quy trình tái lập được, đi từ dữ liệu công bố đến câu trả lời có bằng chứng, và đo ba điều mà các hệ thống mô tả âm thanh thường bỏ qua: học chuyển giao có thật sự giúp không, mô tả có bị ảo giác không, và bộ lọc có cấu trúc đóng góp gì cho việc truy hồi. Cụ thể gồm bảy việc: (1) chuẩn bị dữ liệu có nguồn gốc rõ và tập chia cố định; (2) huấn luyện mô hình phân loại 22 lớp trên DataSEC; (3) huấn luyện mô hình SED 21 lớp trên DataSED; (4) đo hiệu quả của việc chuyển giao DataSEC sang DataSED; (5) sinh mô tả có căn cứ và đo ảo giác; (6) truy hồi kết hợp lọc và tìm theo ngữ nghĩa; (7) làm ứng dụng web minh họa từ đầu đến cuối.

Ba câu hỏi nghiên cứu (Research Question – RQ) chính được tóm tắt ở Bảng 1.1. Câu hỏi phụ về phân loại lớp con chỉ trả lời được trên DataSEC vì DataSED không có nhãn lớp con (xem Chương 6).

Bảng 1.1 Ba câu hỏi nghiên cứu chính

Mã	Câu hỏi	Cách trả lời
RQ1	Huấn luyện thêm trên DataSEC có giúp SED tốt hơn so với chỉ dùng mô hình tiền huấn luyện AudioSet không?	So nhánh C (AudioSet rồi DataSEC) với nhánh B (chỉ AudioSet), nhiều lần chạy, có khoảng tin cậy
RQ2	Bắt mô tả bám sát danh sách sự kiện thì giảm ảo giác bao nhiêu so với viết tự do?	So tỷ lệ ảo giác và bỏ sót giữa các cách sinh, trên cùng một kết quả SED
RQ3	Truy hồi kết hợp (lọc cứng và xếp hạng theo ngữ nghĩa) so với chỉ lọc hoặc chỉ ngữ nghĩa thì sao?	So nDCG@10, Recall và độ đúng bộ lọc; độ liên quan tính bằng máy từ nhãn gốc

Nguồn: docs/SYSTEM.md §1.3; ADR-0002; ADR-0021.

Với RQ1, nhóm so ba nhánh: A học từ đầu, B dùng trọng số tiền huấn luyện AudioSet [8], C dùng AudioSet rồi huấn luyện tiếp trên DataSEC. Phép so sánh đúng là **C với B**, vì C với A trộn lẫn tác dụng của tiền huấn luyện nói chung với tác dụng riêng của DataSEC. Với RQ2, nhóm so các cách sinh mô tả (Chương 4) ở mức *oracle* (dùng sự kiện từ nhãn gốc) và mức *đầu–cuối* (dùng sự kiện do SED dự đoán).

1.4 Phạm vi và giới hạn

Đề tài xử lý âm thanh môi trường ngoài trời theo lô (không phải thời gian thực), gồm SED 21 lớp trên DataSED, phân loại 22 lớp trên DataSEC, mô tả tiếng Anh (để đánh giá) và tiếng Việt (cho giao diện), cùng truy vấn theo lớp, thời gian, thời lượng, độ tin cậy và quan hệ trước–sau.

Một số hướng bị loại có chủ ý vì dữ liệu không đủ cơ sở (ADR-0001): nhận dạng nội dung lời nói hay người nói; suy ra tội phạm, ý định, tai nạn, tình huống khẩn cấp; chấm điểm nguy hiểm. Mô tả chỉ nói về *nguồn âm quan sát được*, không nói về *tình huống*: "phát hiện tiếng kính vỡ lúc 5,4 s" là hợp lệ, còn "phát hiện đột nhập" thì không. Xử lý thời gian thực và định vị nguồn âm trong không gian cũng nằm ngoài phạm vi.

1.5 Đóng góp dự kiến

Đề cương nêu bốn đóng góp dự kiến. Bảng 1.2 cho biết ở mốc giữa kỳ, đóng góp nào đã có bằng chứng, đóng góp nào còn là định hướng. Nhóm **chưa** khảo sát văn liệu có hệ thống, nên chưa dám khẳng định tính mới so với công trình khác; việc này để giai đoạn sau (Chương 7).

Bảng 1.2 Bốn đóng góp dự kiến và mức bằng chứng ở giữa kỳ

Mã	Đóng góp dự kiến	Bằng chứng đã có	Chưa khẳng định
C1	Bộ sinh mô tả có điều kiện bám sát sự kiện, máy kiểm tra được	Ràng buộc có kiểm thử tự động; trên tập test, bộ sinh có ràng buộc không còn ảo giác nguồn âm	Tính mới so với văn liệu
C2	Bộ chỉ số đo mức bám sát của mô tả, không cần câu mẫu	Đo ảo giác, bỏ sót, thứ tự, từ cấm, có khoảng tin cậy; đối chiếu 60 mô tả với một người đọc	Mẫu đối chiếu nhỏ
C3	Đo chuyển giao có kiểm soát trùng lặp giữa hai bộ dữ liệu	Tìm ra ba nhóm trùng, loại 11 đoạn; RQ1 cho kết quả âm tính	Việc "các nghiên cứu khác thường không kiểm tra"
C4	RAG trên dòng thời gian sự kiện, có điều kiện thời gian	Bốn điều kiện thời gian viết bằng SQL; bộ lọc đúng 100%; câu trả lời không có khẳng định thiếu bằng chứng	Tính mới so với văn liệu

Nguồn: docs/PAPER_NOTES.md §2; docs/RELATED_WORK.md §9.

1.6 Bố cục báo cáo

Chương 2 giới thiệu kiến thức nền. Chương 3 mô tả dữ liệu và cách kiểm soát trùng lặp. Chương 4 trình bày phương pháp. Chương 5 mô tả hệ thống đã triển khai. Chương 6 báo cáo kết quả, kể cả kết quả âm tính hoặc kém đi. Chương 7 đối chiếu tiến độ, nêu kết luận giữa kỳ và kế hoạch tiếp theo.

CHƯƠNG 2 CƠ SỞ LÝ THUYẾT

Chương này tóm tắt những kiến thức nền mà đề tài dùng. Nhóm chỉ trích các nguồn đã đọc trực tiếp toàn văn. Những chủ đề chưa có nguồn như vậy được ghi rõ là chưa tổng quan, không viết như thể đã có căn cứ.

2.1 Phát hiện sự kiện âm thanh

Phát hiện sự kiện âm thanh (SED) trả lời câu hỏi "cái gì xảy ra và khi nào" trong tín hiệu âm thanh. Đầu ra gồm lớp sự kiện cùng thời điểm bắt đầu và kết thúc [11]. Vì nhiều nguồn có thể vang cùng lúc, SED đa âm là bài toán phân loại **đa nhãn theo từng khung thời gian**, không phải phân loại một nhãn cho cả đoạn.

Có hai kiểu nhãn [11]. Nhãn mạnh ghi rõ đoạn thời gian của từng sự kiện. Nhãn yếu chỉ cho biết lớp nào có mặt trong bản ghi. Nhãn mạnh tốn công hơn vì người gán nhãn phải nghe lại và đặt biên cho từng sự kiện, mà biên của âm thanh môi trường vốn không rõ nét. Hai bộ dữ liệu của đề tài phản ánh sự khác biệt này: DataSEC có các đoạn rời với nhãn mức đoạn, còn DataSED có bản ghi dài với nhãn mạnh [6].

Đầu vào thường dùng là phổ log-mel, một "ảnh" thời gian–tần số của tín hiệu. Kiến trúc phổ biến là mạng tích chập hồi quy (CRNN) [11]: phần tích chập (CNN) trích đặc trưng từ ảnh phổ, phần hồi quy (ở đây là BiGRU, mạng hồi quy hai chiều) học quan hệ theo thời gian. Mô hình cho ra xác suất của từng lớp tại từng khung. Chuỗi xác suất này chưa phải là sự kiện: nó phải qua bước ghép thành các đoạn (mục "Từ xác suất thành sự kiện" bên dưới). Vì thế chất lượng phát hiện phụ thuộc cả mô hình lẫn bước ghép, và hai phần này đều phải được chọn trên tập dev, không phải trên tập test.

2.2 Cách đánh giá

Metric theo sự kiện. Mesaros và cộng sự phân biệt metric theo đoạn (chia trục thời gian thành các đoạn cố định như 1 s rồi so từng đoạn) với metric theo sự kiện (so từng sự kiện dự đoán với sự kiện tham chiếu cùng lớp) [10]. Một cặp được coi là khớp khi

thời điểm bắt đầu lệch không quá một dung sai (collar). Đề tài dùng collar $\tau = 0{,}2$ s cho thời điểm bắt đầu và, cho thời điểm kết thúc, dung sai

$$\Delta_{off} \le \max(\tau,\ \rho \cdot L_{ref}), \qquad \tau = 0{,}2 \text{ s},\ \rho = 0{,}2 \tag{2.1}$$

với L_{ref} là độ dài sự kiện tham chiếu. Gọi TP, FP, FN là số sự kiện đoán đúng, đoán sai và bị bỏ lỡ. Precision, recall và F1 (gọi tắt là event-F1) được tính như sau:

$$P = \frac{TP}{TP+FP}, \qquad R = \frac{TP}{TP+FN}, \qquad F_1 = \frac{2PR}{P+R} \tag{2.2}$$

F1 theo khung chỉ dùng để kiểm tra huấn luyện chạy đúng. Nhóm không đặt nó cạnh event-F1 như cùng một đại lượng.

Micro và macro. Khi gộp nhiều lớp có hai cách [10]. *Micro* cộng dồn TP, FP, FN của mọi lớp rồi mới tính F1, nên các lớp có nhiều sự kiện chi phối kết quả. *Macro* tính F1 riêng từng lớp rồi lấy trung bình, nên mỗi lớp có trọng số như nhau:

$$F_1^{micro} = F_1(\textstyle\sum_c TP_c,\ \sum_c FP_c,\ \sum_c FN_c), \qquad F_1^{macro} = \frac{1}{|\mathcal{C}|}\sum_{c\in\mathcal{C}} F_{1,c} \tag{2.3}$$

Hai con số trả lời hai câu hỏi khác nhau nên nhóm báo cả hai. Từ 26/09/2026 macro được ghi trước, nhưng các vòng chọn hệ thống vẫn dựa vào micro vì luật chọn đã ghi trước bằng micro và micro ít nhiễu hơn trên tập dev nhỏ (ADR-0031). Trước ngày này, số chính của dự án là micro; việc lệch này được nêu công khai ở Chương 6.

PSDS. Event-F1 gắn với một ngưỡng duy nhất. Điểm PSDS (Polyphonic Sound Detection Score) đánh giá trên cả **dải** ngưỡng, dùng tỷ lệ giao thời gian thay cho collar [1]. Nhóm dùng hai kịch bản cố định trước khi chạy test: PSDS-1 nhấn mạnh việc định vị đúng thời điểm, PSDS-2 nhấn mạnh việc tránh nhầm lớp (docs/evaluation_protocol.md §3.3). Một hệ thống có thể tốt ở kịch bản này mà kém ở kịch bản kia; chênh lệch đó là thông tin cần báo.

Mức khó. Ở thử thách DCASE 2016 (nhiệm vụ 3, ghi âm đời thực), các hệ thống đạt event-F1 chỉ 4,7–6,3% [4]. Con số này chỉ để **định cỡ** độ khó, không so trực tiếp được với kết quả của đề tài vì khác dữ liệu, số lớp và quy tắc collar.

2.3 Từ xác suất thành sự kiện

Cách ghép phổ biến là làm mượt chuỗi xác suất bằng lọc trung vị, so với một ngưỡng θ_c, gộp các khoảng trống ngắn và bỏ sự kiện quá ngắn. Các giới hạn độ dài suy từ thống kê nhãn; nhóm chỉ suy chúng từ tập huấn luyện và quét ngưỡng trên dev (ADR-0003), vì suy từ chính tập đang chấm là một dạng rò rỉ khó thấy.

Ebbers và cộng sự chỉ ra rằng ngưỡng theo khung gắn chặt biên sự kiện với độ tin cậy: ngưỡng càng cao, thời điểm bắt đầu càng bị đẩy về nơi xác suất *đạt* ngưỡng, chứ không phải nơi nó bắt đầu tăng [5]. Họ đề xuất hộp bao sự kiện (SEBB), trong đó ngưỡng chỉ quyết định giữ hay bỏ sự kiện, không dời biên. Biến thể cSEBB xác định biên bằng cách tìm điểm xác suất đổi hướng. Trên 13 hệ thống của DCASE 2023, cSEBB tăng trung bình 4,1 điểm PSDS1 và 3,4 điểm F1 so với lọc trung vị [5]. Kết quả đó đo trên dữ liệu và mô hình khác, nên nhóm xem cSEBB là một lựa chọn phải được kiểm tra bằng kiểm chứng chéo trên dev, không mặc định là tốt hơn.

2.4 Học chuyển giao

Tiền huấn luyện trên AudioSet. Kong và cộng sự công bố họ mạng PANNs, huấn luyện trên AudioSet (hơn 5.000 giờ, 527 lớp) rồi chuyển sang sáu tác vụ âm thanh khác [8]. Mạng CNN14 của họ là điểm xuất phát của nhánh B và C trong RQ1. Một chi tiết quan trọng với SED là các lớp gộp (pooling) làm giảm độ phân giải theo thời gian của đầu ra; Chương 4 cho thấy điều này đặt giới hạn trên đo được cho event-F1.

Tiền huấn luyện theo khung. Schmid và cộng sự tiền huấn luyện transformer âm thanh trên nhãn **theo khung** của AudioSet Strong (đầu ra mỗi 40 ms); trên DESED, đóng băng bộ mã hóa và chỉ huấn luyện một lớp tuyến tính đã đạt PSDS1 45,4–49,2, gần với tinh chỉnh toàn bộ (47,6–49,2) [13]. Vì vậy nhóm thử bộ mã hóa đóng băng trước, do rẻ trên GPU 8 GB; một trong số đó là BEATs, mô hình tự giám sát [3]. Các con số trên đo trên DESED, không phải DataSED, nên chỉ là lý do để thử chứ không phải dự báo kết quả.

Tăng cường dữ liệu. Mixup huấn luyện trên tổ hợp lồi của hai mẫu và nhãn của chúng [14]. FilterAugment nhân trọng số ngẫu nhiên lên các dải tần để mô phỏng ảnh

hưởng của môi trường âm học; trên SED, nó tăng PSDS 6,50% so với 2,13% của che dải tần [12].

Trùng lặp giữa các bộ dữ liệu. Chuyển giao chỉ có nghĩa khi dữ liệu kiểm tra không nằm trong dữ liệu tiền huấn luyện. Bài mô tả DataSEC và DataSED cho biết một phần âm thanh lấy từ Freesound và AudioSet, được cắt, ghép, trộn hoặc sửa tay [6], nên hai bộ có thể chung bản ghi gốc (nhóm kiểm tra ở Chương 3) và mô hình tiền huấn luyện trên AudioSet có thể đã "nghe" một phần âm thanh gốc — rủi ro **không định lượng được** vì danh sách nguồn không được công bố.

2.5 Mô tả có bám sát sự kiện và ảo giác

Ji và cộng sự định nghĩa ảo giác trong sinh văn bản là nội dung "vô nghĩa hoặc không trung thành với nguồn được cung cấp", gồm ảo giác nội tại (mâu thuẫn với nguồn) và ngoại tại (không kiểm chứng được từ nguồn) [7]. Ở đề tài, "nguồn" được định nghĩa hẹp và kiểm tra được: là danh sách sự kiện. Mô tả nhắc đến nguồn âm không có trong danh sách là ảo giác ngoại tại; mô tả đặt sai thứ tự hai sự kiện là ảo giác nội tại.

Cách định nghĩa này cho phép đo ảo giác **mà không cần câu mô tả mẫu do người viết**. Các chỉ số đếm n-gram truyền thống so mô tả với câu mẫu, nên một mô tả bịa vẫn có thể trùng nhiều n-gram mà không bị phát hiện. Nhóm chưa đọc trực tiếp văn liệu về mô tả âm thanh tự động (Automated Audio Captioning – AAC). Vì vậy báo cáo **không** khẳng định bộ chỉ số của nhóm là mới so với lĩnh vực này; việc tổng quan thuộc kế hoạch giai đoạn sau (Chương 7).

2.6 Truy hồi và RAG

Lewis và cộng sự đề xuất RAG: kết hợp một mô hình sinh với một kho dữ liệu ngoài, được truy cập qua bộ truy hồi [9]. Họ cũng nêu việc cung cấp nguồn gốc cho câu trả lời là vấn đề mở. Nhóm áp dụng tinh thần này với hai thay đổi: kho ngoài không phải văn bản tự do mà là các sự kiện có cấu trúc (lớp, bắt đầu, kết thúc, độ tin cậy), và câu trả lời bắt buộc kèm bằng chứng (mã bản ghi, khoảng thời gian); câu trả lời thiếu bằng chứng bị coi là không hợp lệ.

Để câu hỏi tiếng Việt và tiếng Anh dùng chung một kho, nhóm dùng mô hình embedding đa ngữ BGE-M3, hỗ trợ hơn 100 ngôn ngữ và đầu vào dài tới 8192 token [2]. Độ tương đồng vector hợp với câu hỏi mang tính ngữ nghĩa, nhưng không bảo đảm các ràng buộc cứng như "sự kiện dài hơn 30 giây" hay "tiếng kính vỡ trước tiếng còi". Những ràng buộc đó là phép so sánh số và phép nối theo thời gian nên được xử lý bằng bộ lọc trong cơ sở dữ liệu. Truy hồi kết hợp (lai) lọc cứng trước, rồi mới xếp hạng vector trong tập đã lọc, để độ tương đồng ngữ nghĩa không bao giờ ghi đè bộ lọc.

Chất lượng truy hồi được đo bằng các chỉ số xếp hạng chuẩn: Recall@k (tỷ lệ kết quả liên quan nằm trong k kết quả đầu), MRR và nDCG@10 (chỉ số thưởng cho kết quả liên quan được xếp cao); công thức ở Chương 4.

2.7 Vị trí của đề tài

Các nguồn đã đọc cung cấp nền cho từng mắt xích: dữ liệu môi trường có nhãn mạnh [6], chỉ số SED và PSDS [1, 10], ghép biên sự kiện [5], tiền huấn luyện theo đoạn và theo khung [8, 13], ảo giác [7] và RAG [9]. Bài mô tả DataSED không báo cáo mô hình hay chỉ số cơ sở nào [6]. Nhóm chưa tìm kiếm có hệ thống các công trình trích dẫn bộ dữ liệu này, nên không khẳng định kết quả của mình là baseline đầu tiên trên DataSED.

Đề tài tập trung vào phần nối các mắt xích đó: chuyển giao có kiểm soát trùng lặp giữa hai bộ dữ liệu, SED đa âm trên bản ghi môi trường, mô tả bám sát sự kiện kiểm tra được bằng máy, và truy hồi trên dòng thời gian có điều kiện thời gian.

CHƯƠNG 3 DỮ LIỆU

Chương này mô tả hai bộ dữ liệu, các lớp âm thanh và quy trình chuẩn bị dữ liệu (D0–D4). Quy trình bảo đảm mọi tệp đều có nguồn gốc, mọi tệp bị loại đều có lý do, và các tập chia được khóa bằng mã băm (hash) trước khi huấn luyện. Mọi con số trong chương do script tính từ tệp kiểm kê và báo cáo đo; nguồn ghi dưới mỗi bảng.

3.1 Hai bộ dữ liệu

DataSEC và DataSED được công bố trên Zenodo theo giấy phép CC-BY-NC-SA-4.0 và mô tả trong một bài báo trên *Scientific Data* [6]. Giấy phép lấy từ bản ghi Zenodo vì hai tệp nén không có tệp LICENSE. Điều khoản "chia sẻ tương tự" nghĩa là nếu công bố mô hình huấn luyện từ dữ liệu này thì mô hình cũng phải theo cùng giấy phép.

Nhóm không dùng các số thống kê trong bài báo, vì phiên bản DataSEC trong bài (4.292 tệp) cũ hơn bản đã tải, và số tệp, tổng thời lượng của DataSED trong bài khác với tệp nén thực tế. Mọi thống kê dưới đây đo trực tiếp từ tệp nén, đã kiểm kích thước và MD5 trước khi giải nén (DataSEC 6.414.663.316 byte, DataSED 4.510.378.259 byte, cả hai khớp giá trị công bố).

DataSEC (Zenodo 17033970, bản 3) gồm 5.048 tệp WAV đơn kênh 44,1 kHz, tổng 23,71 giờ. Nhãn lấy từ cây thư mục, có hai cấp: 22 lớp gộp và 28 lớp con thuộc 10 lớp gộp. Phân bố lớp rất lệch: voices (1.900 tệp, 37,6%) và music (1.001 tệp, 19,8%) chiếm 57,5%, trong khi lớp nhỏ nhất chỉ có 50 tệp (chênh khoảng 38 lần). Ở cấp lớp con, bốn nút có dưới 25 tệp (crickets, olive_shaker, magpies, lawn_mower) nên mỗi nút chỉ có 3–4 mẫu test. Vì vậy nhóm lấy mẫu cân bằng lớp khi huấn luyện và chỉ báo số tuyệt đối cho các nút có dưới 10 mẫu test.

DataSED (Zenodo 15346092) gồm 717 bản ghi WAV 44,1 kHz, tổng 18,68 giờ, dài trung bình khoảng 94 s. Bộ này có hai bản nhãn mạnh trên cùng âm thanh: bản đa âm (polyphonic) có 4.034 sự kiện thuộc 21 lớp, phủ 703 bản ghi; bản đơn âm có 4.309 sự kiện thuộc 22 lớp, phủ đủ 717 bản ghi. Sự kiện dài từ 0,41 s đến 296,5 s, trung vị

5,8 s. Nhóm chọn bản đa âm làm benchmark chính vì môi trường thật thường có nhiều nguồn cùng lúc.

3.2 Các lớp âm thanh

Hệ lớp (phiên bản 0.1, SHA-256 67ca8a8c…) có 22 lớp với tên tiếng Anh dạng snake_case, ánh xạ một–một từ nhãn gốc; bảng đầy đủ ở Phụ lục A. Ánh xạ đã được kiểm trực tiếp trên tệp nén: 22/22 lớp gộp và 10/10 nhóm lớp con khớp, không có nhãn lạ. Nhãn gốc được giữ nguyên để truy nguồn; gặp nhãn lạ thì quy trình dừng chứ không tự đoán.

Đề tài dùng hai tập lớp khác nhau:

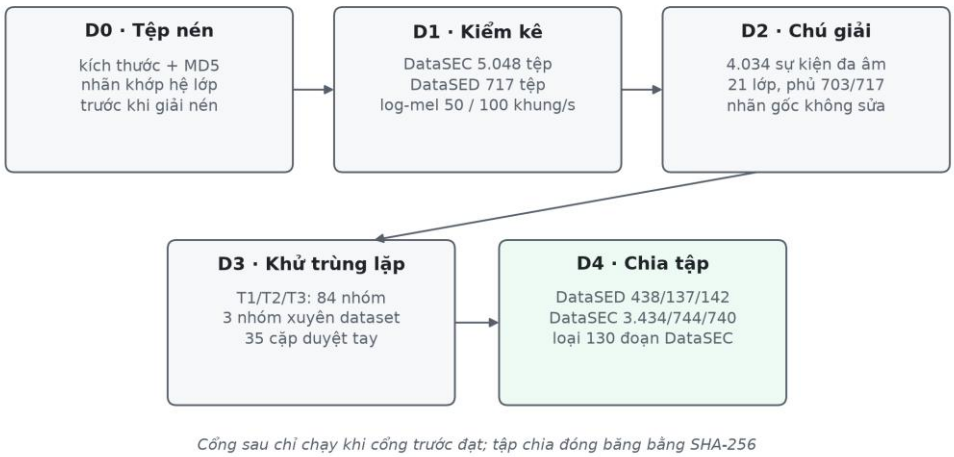
- **22 lớp** cho phân loại DataSEC và cho bản nhãn đơn âm của DataSED.
- **21 lớp đa âm** cho đầu ra SED. Lớp wind_turbine không có trong bản nhãn đa âm.

Kết quả trên 21 lớp đa âm và trên 22 lớp đơn âm **không so sánh trực tiếp được**, vì khác tập lớp, khác định nghĩa nhãn và khác mẫu số khi tính macro.

Hai lớp gộp sirens_and_alarms và thunder_fireworks_gunshot chứa các nguồn âm khác bản chất (còi báo động khác chuông báo; sấm khác pháo hoa và tiếng súng). DataSED chỉ có nhãn ở cấp gộp, nên mô tả về hai lớp này phải giữ đúng mức mơ hồ: viết “một âm thanh xung giống sấm, pháo hoa hoặc tiếng súng”, không viết “một tiếng súng”. Điều này được kiểm thử trong phần sinh mô tả (Chương 4).

3.3 Quy trình chuẩn bị dữ liệu

Quy trình gồm các cổng kiểm tra nối tiếp; cổng sau chỉ chạy khi cổng trước đạt (Hình 3.1).



Hình 3.1 Quy trình chuẩn bị dữ liệu D0–D4 và các tệp đã khóa

Nguồn: scripts/build_midterm_figures.py, đọc data/manifests/{datasec,datased}_inventory_summary.json, datased_preparation_audit.json, duplicate_audit.json và hai tệp split đóng băng.

D0–D2: kiểm tệp nén, kiểm kê, chuẩn hóa nhãn. Cổng D0 kiểm kích thước và MD5 **trước** khi giải nén và đối chiếu cây nhãn với hệ lớp; việc bỏ qua kiểm tra được ghi thành kết luận riêng để không bao giờ bị đọc nhầm là "đạt". Cổng D1 ghi tần số lấy mẫu, số kênh, thời lượng, SHA-256 của từng tệp và trích sẵn đặc trưng log-mel (logmel_v1: 16 kHz, 64 mel, 50 khung/s, cho mô hình học từ đầu; logmel_panns_v1: 32 kHz, 64 mel, 100 khung/s, cho mô hình họ PANNs). Cổng D2 chuyển nhãn DataSED thành bảng sự kiện; nhãn gốc không bao giờ bị sửa, nghi ngờ nhãn nào thì ghi phân tích lỗi thay vì chỉnh dữ liệu.

D3: tìm bản trùng. D3 là cổng quan trọng nhất cho RQ1. Hai bộ dữ liệu có cùng sáu tác giả, cùng miền và công bố cách nhau bốn tháng, nên nhóm giả định hai bộ *có thể* chung bản ghi gốc cho tới khi đo được điều ngược lại. Bản trùng được tìm ở ba tầng, cả trong từng bộ lẫn giữa hai bộ: **T1** so mã băm byte của tệp; **T2** so mã băm tín hiệu sau khi giải mã và lấy mẫu lại về 16 kHz đơn kênh; **T3** so dấu vân tay âm học (20 hệ số MFCC mỗi khung 1 s, chuẩn hóa theo toàn kho, so bằng độ tương đồng cosine trên đoạn chồng lấp dài nhất, ADR-0007).

Ngưỡng của T3 được hiệu chuẩn bằng dữ liệu, gồm 24 cặp giống hệt byte (dương) và 5.000 cặp ngẫu nhiên khác nhãn (âm). Dấu vân tay theo đặc tả ban đầu cho 52,6%

cặp âm vượt ngưỡng xem xét, tức không dùng được. Sau khi bỏ hệ số C_0 và chuẩn hóa theo kho, cặp dương thấp nhất đạt 1,0000, cặp âm cao nhất đạt 0,9205 và không cặp âm nào đạt 0,95. Từ đó nhóm đặt: cặp chồng lấp từ 3 s trở lên là duplicate khi độ tương đồng ≥ 0,95, và vào hàng đợi xem xét khi nằm trong [0,85; 0,95). Cặp chồng lấp dưới 3 s không bao giờ được tự động coi là trùng, vì các cặp "xem xét" giả có đoạn chồng lấp trung vị đúng 1 s — hệ quả của việc so sánh khoảng 16,6 triệu cặp (ADR-0009).

Bảng 3.1 Kết quả khử trùng lặp D3 và kiểm tra trùng giữa các tập D4

Cổng	Chỉ báo	Kết quả	Diễn giải
D3	Cặp ứng viên T1/T2/T3	24/24/45191	Audit 3 tầng
D3	Nhóm duplicate	84	Nội bộ và xuyên dataset
D3	Nhóm xuyên DataSEC–DataSED	3	Đã gom theo leakage group
D3	Clip pretraining bị loại	11	Trùng DataSED dev/test
D4	Cổng DataSEC	PASS	5/5 kiểm tra đạt
D4	Cổng DataSED	PASS	5/5 kiểm tra đạt

Nguồn: data/manifests/duplicate_audit.json; data/manifests/datasec_leakage_report.json; data/manifests/datased_leakage_report.json; data/splits/datasec_classification.frozen.json. Bảng sinh tự động bởi script, không sửa tay.

Bảng 3.1 xác nhận rủi ro là có thật. Có ba nhóm trùng giữa hai bộ dữ liệu, trong đó hai cặp có độ tương đồng 1,000000 trên đoạn chồng lấp 35 s và 13 s: Sirens-0046 (DataSEC) với S-0233 (DataSED), và Sirens-0067 với S-0211. Cặp thứ ba là Train-0012 với S-0213 (0,9548 trên 31 s). Thêm 35 cặp giữa hai bộ nằm ở vùng xem xét được duyệt tay bằng cách nghe: 10 cặp trùng, 1 cặp không chắc (xử lý thận trọng như trùng) và 24 cặp khác nhau. Sau D3, 11 đoạn DataSEC trùng với bản ghi DataSED thuộc dev hoặc test bị loại khỏi dữ liệu tiền huấn luyện. Con số này là 0,2179% DataSEC, nằm trong dải "nhỏ" (dưới 1%) mà kế hoạch dữ liệu quy định là loại bỏ, ghi nhận và vẫn giữ hiệu lực của RQ1. Trong nội bộ DataSEC còn 119 đoạn bị loại vì là bản sao, nên tổng số đoạn không vào tập chia là 130.

D4: chia tập. Đơn vị chia là **nhóm trùng** (leakage_group), không phải từng tệp: các tệp giống nhau hoặc rất giống nhau luôn nằm cùng một tập. DataSED chia 60/20/20 theo bản ghi, phân tầng theo nhãn, seed 20260922 (ADR-0008); DataSEC chia 70/15/15 theo lớp gộp. Ngưỡng gom cặp tương tự được đặt 0,93, trên mức nhiễu đã

đo (0,9205); với 0,85, hiện tượng nối chuỗi tạo một khối 315 tệp trộn tiếng nói với tiếng nổ và làm tỷ lệ chia lệch 5 điểm phần trăm (ADR-0012).

Bảng 3.2 Hai bộ dữ liệu và tập chia đã khóa

Dataset	Bài toán	File	Giờ	Train	Validation	Test	Nhóm leakage	SHA split
DataSEC	Phân loại	5048	23.71	3434	744	740	4873	e8d3099010ac…
DataSED	SED đa âm	717	18.68	438	137	142	687	d2924a5e45c2…

Nguồn: data/manifests/datasec_inventory_summary.json; data/manifests/datased_inventory_summary.json; data/splits/datasec_classification.frozen.json; data/splits/datased_polyphonic.frozen.json. Bảng sinh tự động bởi script, không sửa tay.

Cổng D4 kiểm năm điều kiện trước khi khóa: không nhóm nào nằm ở hai tập, không mã băm nào nằm ở hai tập, không cặp trùng nào xuyên tập, mọi lớp có mẫu ở mỗi tập, và các đoạn đã loại thật sự vắng mặt (Bảng 3.2). Cả hai bộ dữ liệu đạt 5/5. Cổng này được chứng minh **không đạt rỗng**: khi gỡ danh sách loại trừ, kiểm tra thứ năm thất bại và chỉ đúng tệp Sirens-0046.wav. Phép thử ngược này cần thiết vì từng có hai lỗi lệch cách đặt tên định danh (recording_id và file_id) khiến mọi phép giao thành rỗng, mà phép giao rỗng thì luôn báo "sạch". Hai tập chia được khóa bằng SHA-256; nếu sửa tệp chia sau khi khóa, cổng D4 từ chối chạy.

3.4 Nhãn thiếu và độ nhất quán của nhãn

Bản ghi thiếu nhãn đa âm. Nhóm phát hiện bản nhãn đa âm chỉ phủ 703/717 bản ghi. Mười bốn bản ghi S-0704 đến S-0717 (đều mang nhãn wind_turbine) không có dòng nhãn đa âm nhưng vẫn nằm trong tập chia: 8 ở train, 3 ở dev, 3 ở test. Nếu chấm điểm trên chúng, mọi dự đoán bị tính là báo động nhầm dù thực chất chỉ là thiếu nhãn. Nhóm không chia lại tập (đã khóa) mà thêm một tập đánh giá annotated chỉ gồm bản ghi có nhãn đa âm: dev còn 134, test còn 139 bản ghi (ADR-0034). Từ vòng chọn hệ thống cuối, mọi kiểm chứng chéo và đánh giá test dùng tập này. Các kết quả cũ trên tập all (142 bản ghi test) được giữ và ghi rõ tập đánh giá khi trích.

Hai lần gán nhãn cho cùng một bản ghi. DataSED có 8 cặp bản ghi giống hệt byte nhưng được gán nhãn độc lập hai lần, cho một phép đo độ nhất quán có sẵn. Trên 8 cặp này, 67/94 biên sự kiện lệch không quá 0,2 s, độ lệch biên lớn nhất là 12,72 s, và

2/8 cặp bất đồng về lớp hoặc số sự kiện. Coi một lần gán là "dự đoán" của lần kia, event-F1 giữa người với người ở collar 0,2 s là 0,5785. Nghĩa là collar 0,2 s chặt hơn độ chính xác của chính nhãn, và một cải thiện nhỏ hơn mức bất đồng này không phân biệt được với nhiễu nhãn. Do chỉ có 8 cặp, đây là tín hiệu cảnh báo chứ không phải một nghiên cứu về độ nhất quán.

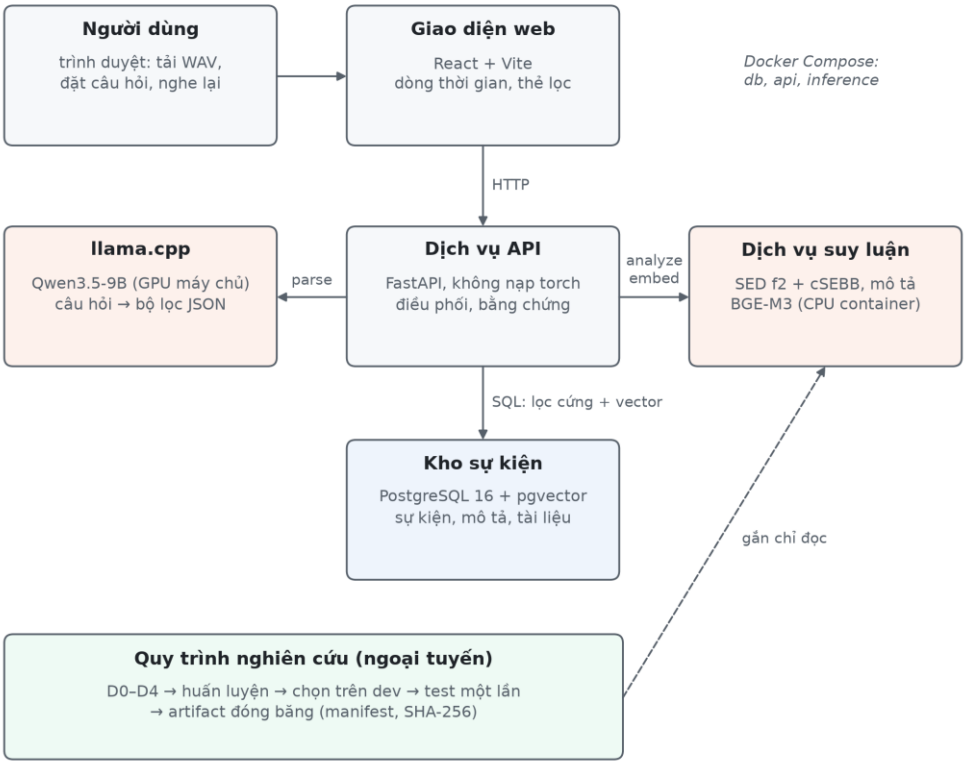
Các rủi ro dữ liệu còn lại — trùng nguồn với AudioSet (không định lượng được), tập dev và test nhỏ, bốn nút lớp con ít mẫu và âm thanh thêm bằng tay [6] — được nêu ở phần hạn chế của Chương 6.

CHƯƠNG 4 PHƯƠNG PHÁP

Chương này trình bày phương pháp theo luồng dữ liệu của hệ thống: mô hình phân loại, các thế hệ mô hình SED, bước ghép thành sự kiện, sinh mô tả, truy hồi và cách đánh giá. Mỗi lựa chọn đều nêu lý do. Các quyết định thiết kế được ghi thành bản ghi quyết định kiến trúc (ADR) trong thư mục docs/decisions/; báo cáo dẫn số ADR khi cần truy nguồn.

4.1 Kiến trúc tổng thể

Hệ thống gồm năm khối nối tiếp (Hình 4.1). Bản ghi âm đi qua dịch vụ suy luận để thành danh sách sự kiện. Danh sách này được dùng theo hai hướng: sinh mô tả bám sát sự kiện, và lưu vào kho sự kiện để truy hồi. Câu hỏi của người dùng được chuyển thành bộ lọc, truy hồi trong kho, rồi trả lời kèm bằng chứng. Ranh giới quan trọng nhất là **bước ghép xác suất thành sự kiện thuộc dịch vụ suy luận, không thuộc mô hình**: ngưỡng và tham số là kết quả hiệu chuẩn trên dev, lưu cạnh checkpoint và nạp khi phục vụ. Nhờ vậy đổi được điểm vận hành mà không cần huấn luyện lại.



Hình 4.1 Kiến trúc tổng thể của hệ thống

Nguồn: scripts/build_midterm_figures.py; đối chiếu services/, ml/inference/, docker-compose.yml.

Đề tài so sánh nhiều thế hệ mô hình nên báo cáo dùng một số mã gọi tắt, giải thích ở Bảng 4.1. Mỗi mã ứng với một thư mục huấn luyện có đầy đủ cấu hình để tái lập.

Bảng 4.1 Các mã gọi tắt của mô hình và ứng viên SED

Mã	Ý nghĩa
A, B, C	Ba nhánh của RQ1: học từ đầu; khởi tạo AudioSet; AudioSet rồi huấn luyện thêm trên DataSEC
v1	Công thức SED ban đầu: CNN14 nén thời gian 64 lần, 8 epoch
v2	Công thức cải tiến: nén 8 lần, BiGRU 2×256, 30 epoch, tăng cường dữ liệu
T2a, T2b	Bộ mã hóa tiền huấn luyện theo khung: BEATs đóng băng (T2a); Frame-MobileNet tinh chỉnh toàn bộ (T2b)
a – e	Ứng viên từ v1/v2: a = ensemble C của v1; b = một run v2; c = ensemble 3 seed v2; d = ensemble 3 seed C-v2; e = ensemble 6 mô hình B-v2 và C-v2
f1 – f4	Ứng viên Track 2: f1 = T2a×3; f2 = T2b×3; f3 = T2a×3 + B-v2×3; f4 = T2b×3 + B-v2×3
g1, g2	Ứng viên dùng focal loss: g1 = T2b focal×3; g2 = g1 kết hợp f2
S13	Vòng chọn hệ thống SED cuối cùng; hệ được khóa là **f2**

Nguồn: ADR-0030, ADR-0031 §4, ADR-0032, ADR-0038; docs/measurements/s13_selection_20261018.md.

4.2 Mô hình phân loại trên DataSEC

Mô hình phân loại có hai vai trò: là bước giữa của nhánh C trong RQ1, và trả lời câu hỏi phụ về việc tách lớp con. Mô hình gồm bộ mã hóa CNN14 khởi tạo từ checkpoint AudioSet và hai đầu tuyến tính, một cho 22 lớp gộp và một cho 28 lớp con (ADR-0016). Checkpoint gốc có các khối tiền xử lý và đầu phân loại mà bộ mã hóa của nhóm không có, nên chỉ sáu khối tích chập được chuyển sang, chiếm 92,23% tham số (ADR-0018). Lớp chuẩn hóa đầu vào được thay bằng chuẩn hóa theo thống kê tập huấn luyện DataSEC.

Hàm mất mát có thêm một số hạng "nhất quán" phạt việc đặt xác suất lớp con vào sai lớp gộp — điều mà cross-entropy 28 lớp một mình không phạt khi lớp đúng vẫn có xác suất cao nhất. Hệ số của số hạng này là 0,5, chọn bằng quét trên dev với điều kiện không làm giảm macro-F1. Vì voices và music chiếm 57,5% dữ liệu, huấn luyện dùng lấy mẫu cân bằng lớp. Khi huấn luyện hai lần cùng seed, hai checkpoint có SHA-256 giống hệt nhau.

4.3 Mô hình phát hiện sự kiện (SED)

Hàm mất mát. Mô hình SED dự đoán xác suất cho 21 lớp ở từng khung trên cửa sổ 10 s; mất mát là binary cross-entropy có mặt nạ cho khung đệm, kèm trọng số lớp dương có trần (v1: 50; từ v2: 10 sau ablation trên dev, ADR-0028) để bù việc thời gian "có sự kiện" ít hơn nhiều.

Thế hệ v1 và ba nhánh của RQ1. Nhánh A dùng mạng CRNN nhỏ (ba khối tích chập và BiGRU) học từ đầu. Nhánh B và C dùng CNN14: B khởi tạo từ AudioSet, C khởi tạo từ bộ mã hóa của mô hình phân loại DataSEC (ADR-0002, ADR-0020). Ba nhánh cùng tập chia, cùng 8 epoch, cùng cửa sổ 10 s bước 5 s, và bước ghép được hiệu chuẩn riêng trên dev của từng nhánh.

Phân tích sau đó cho thấy v1 có một giới hạn cấu trúc: CNN14 trong mã nguồn gộp trục thời gian ở cả sáu khối, tức nén 64 lần, nên mỗi quyết định ứng với khối khoảng 0,64 s. Phép đo ở Chương 6 cho thấy riêng giới hạn này đã chặn event-F1 ở 0,6294, ngay cả khi mô hình nhận dạng hoàn hảo.

Thế hệ v2. SED v2 sửa các nguyên nhân đã đo được thay vì dò siêu tham số (ADR-0030): chỉ gộp thời gian ở ba khối đầu (nén 8 lần, 80 ms mỗi khung); thêm BiGRU hai lớp 256 đơn vị; huấn luyện 30 epoch với tốc độ học giảm dần; và dùng tăng cường dữ liệu gồm cắt cửa sổ ngẫu nhiên, mixup [14] và FilterAugment [12]. Checkpoint được chọn theo average precision theo khung trên dev, đại lượng không phụ thuộc ngưỡng. Từng thành phần được đánh giá bằng ablation bỏ-từng-phần trên dev.

Bộ mã hóa tiền huấn luyện theo khung (Track 2). Dựa trên kết quả "đóng băng gần bằng tinh chỉnh" [13], nhóm thử hai bộ mã hóa tiền huấn luyện trên AudioSet Strong có độ phân giải 40 ms (ADR-0032), sau khi mỗi bộ vượt cổng kiểm tra về bộ nhớ GPU và độ khớp đầu ra:

- **T2a** dùng BEATs [3] **đóng băng** hoàn toàn (khoảng 90,4 triệu tham số), cộng đầu BiGRU của v2 (khoảng 3,3 triệu tham số được huấn luyện).

- **T2b** dùng Frame-MobileNet (frame_mn10, khoảng 3 triệu tham số), **tinh chỉnh toàn bộ**, không có mô hình chuỗi. Đầu vào là sóng âm 16 kHz; đầu ra 250 bước cho 10 s qua một lớp tuyến tính 21 lớp, rồi nội suy lên lưới nhãn 10 ms.

Checkpoint ngoài được kiểm SHA-256 và giấy phép (MIT) trước khi dùng. Một nhánh phụ thay mất mát bằng focal loss trên T2b (ADR-0038) tạo ra ứng viên g1 và g2.

Gộp nhiều mô hình. Vì huấn luyện SED không tất định kể cả khi cùng seed, mỗi cấu hình chạy ba seed và ứng viên là trung bình xác suất của các mô hình (ensemble), chỉ được gộp khi bản ghi, mặt nạ, nhãn và hệ lớp khớp tuyệt đối. Danh sách 11 ứng viên và luật chọn được ghi **trước** khi có kết quả (ADR-0031): chọn ứng viên có event-F1 micro cao nhất theo kiểm chứng chéo 5 fold trên dev, chia fold theo nhóm trùng.

4.4 Ghép xác suất thành sự kiện

Có hai cách ghép, và cách nào cũng được chọn trên dev.

Ngưỡng. Làm mượt xác suất bằng lọc trung vị, so với ngưỡng θ, gộp khoảng trống ngắn và bỏ sự kiện quá ngắn; hai giới hạn độ dài suy từ tập **huấn luyện** (sự kiện ngắn nhất: phân vị 5; khoảng trống tối đa: phân vị 50 theo ADR-0003 hoặc 25 theo ADR-0024). Ngưỡng riêng cho từng lớp có 21 bậc tự do và quá khớp dev (Chương 6), nên từ ADR-0024 nhóm dùng một ngưỡng chung, chọn bằng kiểm chứng chéo 5 fold trên dev.

cSEBB. Nhóm tự cài đặt cSEBB theo bài báo [5] (không dùng mã tham chiếu vì giấy phép AGPL). Ý chính: so trung bình xác suất của một cửa sổ ngắn ngay trước và sau mỗi thời điểm; chỗ tăng mạnh nhất mở sự kiện, chỗ giảm mạnh nhất đóng sự kiện; hai sự kiện gần nhau được gộp nếu chỗ lõm giữa chúng không sâu; ngưỡng chỉ quyết định giữ hay bỏ sự kiện, không dời biên. Hệ f2 được khóa với cửa sổ 0,64 s và gộp theo tỷ lệ 2.

4.5 Sinh mô tả bám sát sự kiện

Ba ràng buộc. Bộ sinh mô tả chỉ nhận danh sách sự kiện sau khi ghép, không nhận âm thanh hay thông tin bối cảnh. Thiết kế này có chủ ý: bộ sinh không thể bịa một nguồn âm mà nó chưa thấy bằng chứng. Mỗi mô tả phải thỏa ba ràng buộc, đều có kiểm thử tự động:

- **G1:** mọi nguồn âm được nhắc đều thuộc danh sách sự kiện (kiểm bằng từ điển cụm từ → lớp).
- **G2:** mỗi lần nhắc đều gắn với mã sự kiện làm bằng chứng.
- **G3:** không có từ về nguyên nhân, ý định, bối cảnh hay nguy hiểm, như *emergency*, *crime*, *intruder*.

Hai lớp gộp phải giữ mức mơ hồ (Chương 3). Danh sách rỗng được mô tả là "không phát hiện sự kiện thuộc các lớp mục tiêu", không phải "bản ghi im lặng".

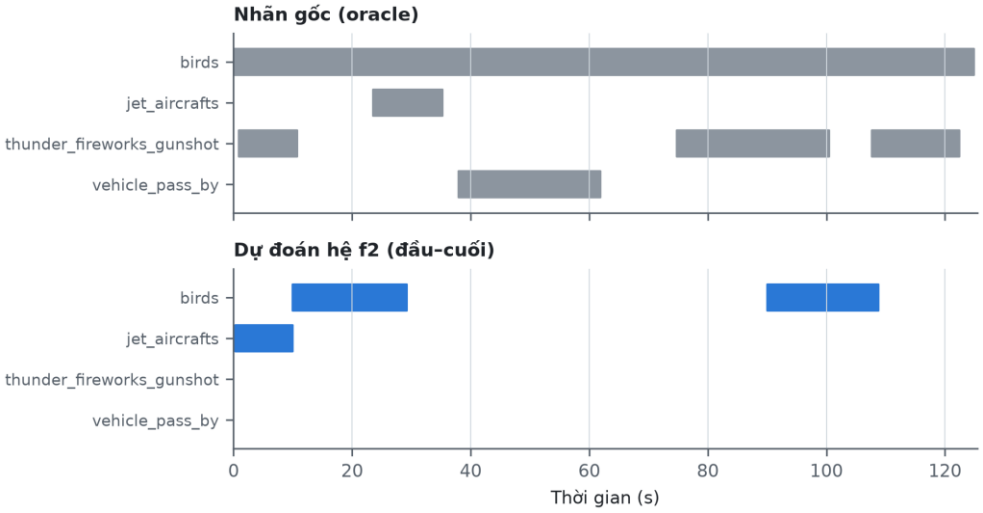
Bốn cách sinh. RQ2 so bốn cách trên **cùng một** kết quả SED đã khóa:

- **Template**: câu tất định từ danh sách sự kiện; bám sát theo thiết kế, dùng để kiểm tra bộ đo.
- **Unconstrained**: mô hình ngôn ngữ Qwen3.5-9B (bản nén Q4_K_M, chạy cục bộ bằng llama.cpp, nhiệt độ 0) viết tự do (ADR-0022).
- **Constrained**: cùng mô hình và lời nhắc, nhưng bị giới hạn bằng một ngữ pháp giải mã (ADR-0023). Ngữ pháp chỉ cho phép một câu liệt kê một dãy con các sự kiện theo thứ tự bắt đầu, mỗi sự kiện tối đa một lần, với tên nguồn âm lấy từ từ điển và thời điểm lấy đúng từ sự kiện. Nhờ vậy ảo giác nguồn âm, từ cấm, thời điểm bịa và sai thứ tự bị loại *theo cấu tạo*; mô hình chỉ còn chọn nhắc sự kiện nào và dừng ở đâu.
- **Constrained-cover**: như constrained, nhưng bắt buộc nhắc sự kiện đầu tiên của mỗi lớp (ADR-0026), nên bỏ sót lớp cũng bị loại theo cấu tạo.

Mô tả tiếng Anh dùng cho đánh giá; mô tả tiếng Việt dùng cho giao diện, sinh bằng template với từ điển tiếng Việt riêng và khớp có giữ dấu (ADR-0025). Từ điển tách

riêng để mã băm của từ điển tiếng Anh dùng cho RQ2 không đổi; giữ dấu vì bỏ dấu sẽ khiến G3 khớp nhầm, như "tới phạm vi" bị đọc thành "tội phạm".

Hình 4.2 đặt cạnh nhau danh sách sự kiện từ nhãn gốc và từ dự đoán của hệ f2 trên bản ghi dev S-0009. Mô tả constrained-cover sinh từ dự đoán là: *"The sound of jet aircrafts can be heard from 0.3 to 10.0 seconds, followed by the sound of birds from 10.0 to 29.2 seconds and the sound of birds from 90.0 to 108.8 seconds."* Mọi nguồn âm và mốc thời gian trong câu đều có sự kiện dự đoán tương ứng, nên câu hợp lệ theo G1–G3. Nhưng so với nhãn gốc, câu đặt tiếng máy bay phản lực sai chỗ và bỏ qua ba sự kiện xung và một sự kiện xe chạy qua. Đây là khoảng cách giữa "bám sát dự đoán" và "đúng với âm thanh" được phân tích ở phần đánh giá và Chương 6.



Hình 4.2 Sự kiện nhãn gốc và dự đoán của hệ f2 trên bản ghi dev S-0009

Nguồn: ml/runs/sed_ensemble_s13_f2_20260929T045053Z/captions/constrained_cover_dev.jsonl (tập dev, mức oracle và đầu–cuối); sinh bằng scripts/build_midterm_figures.py.

4.6 Truy hồi và trả lời có bằng chứng

Kho sự kiện. Nhóm dùng PostgreSQL 16 với phần mở rộng pgvector (ADR-0005), để bộ lọc, điều kiện thời gian và xếp hạng vector nằm trong **một** câu truy vấn SQL. Bảng sự kiện chứa cả nhãn gốc lẫn dự đoán, phân biệt bằng một cột nguồn gốc, để không đánh giá mô hình trên chính đầu ra của nó. Mỗi bản ghi có một tài liệu truy hồi ghép mô tả template tiếng Anh, tiếng Việt và một tóm tắt sự kiện chuẩn hóa (lớp,

thời điểm, số sự kiện), vì mô tả tự nhiên hay bỏ qua con số (ADR-0027). Tài liệu được nhúng bằng BGE-M3 (1024 chiều) [2] và xếp hạng theo khoảng cách cosine.

Ba chế độ truy hồi được so sánh cho RQ3: **structured_only** chỉ lọc cứng; **vector_only** chỉ xếp hạng cosine, không lọc; **hybrid** lọc cứng trước rồi xếp hạng cosine trong tập đã lọc. Bộ lọc gồm tập lớp phải có mặt, ràng buộc thời lượng và một điều kiện thời gian giữa hai lớp a, b trong cùng bản ghi (Bảng 4.2). Mỗi điều kiện được viết một lần dạng SQL (để truy hồi) và một lần dạng Python (để tính độ liên quan từ nhãn gốc); một kiểm thử so hai dạng trên SQLite để bảo đảm cùng ngữ nghĩa.

Bảng 4.2 Bốn điều kiện thời gian giữa sự kiện a và b

Điều kiện	Ý nghĩa	Ví dụ câu hỏi
before	a kết thúc trước khi b bắt đầu	Tiếng kính vỡ trước tiếng còi
after	a bắt đầu sau khi b kết thúc	Tiếng còi sau tiếng kính vỡ
overlaps	a và b chồng nhau	Tiếng nói chồng với tiếng máy
within	a nằm trọn trong b	Tiếng chim trong lúc có tiếng công trường

Nguồn: ml/retrieval/temporal.py (bảng PREDICATES); điều kiện có dung sai τ khai báo trong truy vấn, mặc định 0.

Bộ phân tích câu hỏi. Câu hỏi tiếng Việt hoặc tiếng Anh được chuyển thành bộ lọc JSON bằng cùng mô hình ngôn ngữ cục bộ, bị ràng buộc bởi lược đồ sinh từ 21 lớp và bốn điều kiện (ADR-0036), nên không thể tạo lớp hay điều kiện không tồn tại. Lược đồ chỉ bảo đảm *hình thức*, không bảo đảm *nghĩa* (vẫn có thể đảo vai trò a/b), nên độ đúng ngữ nghĩa được đo riêng (Chương 6). Trên giao diện, bộ lọc hiện thành thẻ để người dùng sửa trước khi truy vấn.

Câu trả lời có bằng chứng được sinh tất định từ các bản ghi đã truy hồi: mỗi câu nhắc lại một sự kiện bằng chứng (lớp, khoảng thời gian); không có kết quả thì trả danh sách bằng chứng rỗng kèm bộ lọc đã áp, không suy diễn; không nêu nguyên nhân hay mức nguy hiểm. Một bộ kiểm độc lập đếm khẳng định không có bằng chứng tương ứng (tỷ lệ khẳng định thiếu bằng chứng).

4.7 Cách đánh giá

Chọn trên dev, kiểm tra một lần. Tập train dùng để tối ưu mô hình và suy giới hạn độ dài. Tập dev dùng để chọn ngưỡng, checkpoint và cấu hình. Tập test chỉ dùng để

đo cấu hình đã chọn, **một lần**. Từ SED v2, quy trình được siết thêm: các lần huấn luyện không sinh dự đoán test; lựa chọn trên dev được commit vào git **trước** khi sinh dự đoán test bằng một đường riêng, và một tùy chọn kiểm chứng đường này tái tạo trùng từng bit dự đoán dev. Mọi lần chạm test được ghi vào một sổ sinh tự động. Mọi cấu hình đã chạy trên test đều được báo cáo, kể cả cấu hình kém, và không cấu hình nào được chọn lại sau khi xem test.

Chỉ số cho mô tả. Gọi $\mathcal{M}$ là tập nguồn âm được nhắc trong một mô tả (trích bằng từ điển) và $\mathcal{C}$ là tập lớp trong danh sách sự kiện. Tỷ lệ ảo giác H và tỷ lệ bỏ sót O là

$$H = 1 - \frac{|\{m \in \mathcal{M} : m \in \mathcal{C}\}|}{|\mathcal{M}|}, \qquad O = 1 - \frac{|\{c \in \mathcal{C} : c \text{ được nhắc}\}|}{|\mathcal{C}|} \tag{4.1}$$

rồi lấy trung bình trên các bản ghi. Bỏ sót tính theo **lớp**, không theo sự kiện. Khi một cụm từ mơ hồ ứng với nhiều lớp, cách tính nghiêng về phía có lợi cho mô tả, nên hiệu số giữa hai cách sinh là một cận dưới. Nhóm còn báo tỷ lệ cặp nhắc đúng thứ tự thời gian, tỷ lệ gọi tên quá cụ thể (ví dụ nói "xe cứu thương" khi lớp chỉ là sirens_and_alarms), tỷ lệ thêm bối cảnh và tỷ lệ dùng từ cấm.

Phạm vi diễn giải cần nêu rõ. Ở mức đầu–cuối, $\mathcal{C}$ là tập lớp của danh sách **dự đoán**. Vì vậy $H = 0$ chỉ có nghĩa là mô tả trung thành với đầu ra SED, không có nghĩa là đúng với âm thanh: một sự kiện SED phát hiện sai vẫn được mô tả "có căn cứ" nhưng sai so với thực tế. Mức oracle, dùng nhãn gốc làm danh sách, tách riêng phần lỗi do bộ sinh mô tả.

Chỉ số cho truy hồi. Gọi R_q là tập bản ghi liên quan của truy vấn q, tính từ **nhãn gốc** bằng đúng ngữ nghĩa của bộ lọc, và r_i là bản ghi xếp thứ i. Với độ liên quan nhị phân:

$$\text{Recall@}k = \frac{|\{r_1..r_k\} \cap R_q|}{|R_q|}, \qquad \text{nDCG@10} = \frac{\sum_{i=1}^{10} \mathbb{1}[r_i \in R_q] / \log_2(i+1)}{\sum_{i=1}^{\min(|R_q|,10)} 1/\log_2(i+1)} \tag{4.2}$$

MRR là nghịch đảo hạng của kết quả liên quan đầu tiên. Độ đúng bộ lọc là tỷ lệ kết quả thỏa **mọi** bộ lọc cứng; structured_only và hybrid phải đạt 1,000, thấp hơn là lỗi kiến trúc chứ không phải hiệu năng kém. Bộ truy vấn gồm 100 câu thuộc bốn nhóm

(21 một lớp, 27 nhiều lớp, 30 quan hệ thời gian, 22 thời lượng), chọn theo nhãn tập **train** trước khi xem kết quả; trên test có 97/100 câu có ít nhất một bản ghi liên quan.

Khoảng tin cậy. Các khung thời gian không độc lập, nên đơn vị lấy mẫu lại là **bản ghi**: khoảng tin cậy 95% là khoảng phân vị của chỉ số trên 1000 mẫu lại có hoàn lại (seed 20260922); với truy hồi, đơn vị là truy vấn. Khi so hai hệ thống trên cùng tập, hiệu số được bootstrap **ghép cặp**; khi so nhiều seed, nhóm dùng thêm kiểm định t của Welch. Quy tắc diễn giải: chênh lệch có khoảng tin cậy chồng lấp, hoặc nhỏ hơn độ lệch chuẩn giữa các fold hay các seed, **không** được gọi là cải thiện.

CHƯƠNG 5 TRIỂN KHAI HỆ THỐNG

Chương này mô tả phần đã làm thành phần mềm: cách tổ chức mã nguồn, các dịch vụ, giao diện, cách chạy demo và cách bảo đảm tái lập. Nội dung chỉ gồm những gì đã có mã nguồn và đã được kiểm chứng bằng lệnh và tệp kết quả.

5.1 Tổ chức mã nguồn

Mã nguồn chia ba tầng: ml/ chứa phần xử lý dữ liệu, mô hình, huấn luyện, đánh giá, sinh mô tả và truy hồi; scripts/ chỉ gọi các chức năng đó từ dòng lệnh và sinh báo cáo đo; services/ chứa các dịch vụ phục vụ.

Hai nguyên tắc ranh giới được kiểm bằng máy chứ không chỉ là quy ước. Thứ nhất, dịch vụ API không được dùng PyTorch hay nạp checkpoint; một kiểm thử trong quy trình tích hợp liên tục (CI) chặn việc này, để API khởi động nhanh và kiểm thử được mà không cần GPU. Thứ hai, dữ liệu trao đổi giữa các thành phần tuân theo các hợp đồng JSON Schema trong contracts/ (bản ghi, sự kiện, dòng thời gian, phản hồi suy luận, kết quả truy hồi, tham số hậu xử lý, bộ truy vấn, manifest của lần chạy), mỗi hợp đồng có kiểm thử riêng.

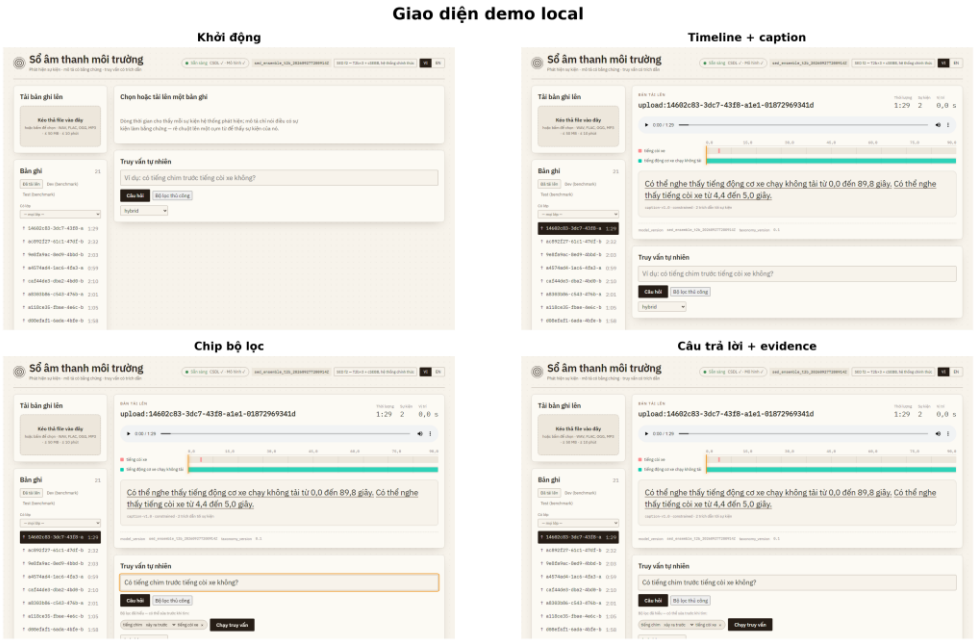
5.2 Các dịch vụ

Dịch vụ suy luận (FastAPI) nạp **một lần** khi khởi động: mô hình SED đang phục vụ kèm tham số ghép sự kiện, các bộ sinh mô tả, và mô hình embedding BGE-M3. Mô hình phục vụ được chọn qua biến môi trường, và kiến trúc mạng được dựng lại từ manifest chứ không mã hóa cứng. Dịch vụ trả cờ official cho biết lần chạy đang phục vụ có đúng là hệ đã khóa (f2) hay không; giao diện hiển thị cờ này.

Dịch vụ API (FastAPI) nhận tệp tải lên, kiểm tra đầu vào, lưu trữ và điều phối. Mọi phản hồi theo một khuôn chung {success, data, error, meta}. Tệp bị từ chối nếu sai định dạng âm thanh, lớn hơn 50 MB hoặc dài hơn 600 s. Các chức năng chính: tải lên và phân tích; xem bản ghi cùng dòng thời gian, mô tả có bằng chứng và phát lại âm thanh; chuyển câu hỏi thành bộ lọc; truy hồi kèm câu trả lời có bằng chứng; xem trạng thái mô hình đang phục vụ.

Cơ sở dữ liệu PostgreSQL gồm bảy bảng. Ba quyết định thiết kế có ý nghĩa phương pháp: bảng caption_evidence nối mô tả với sự kiện — đó chính là định nghĩa của "có căn cứ", một mô tả không có dòng bằng chứng nào là vi phạm; bảng tài liệu truy hồi tách khỏi bảng mô tả để đổi mô hình embedding mà không phải sinh lại mô tả; và cột nguồn gốc trên bảng sự kiện phân biệt nhãn gốc với dự đoán. Truy vấn dùng chỉ mục thường cho lớp và thời gian, chỉ mục GIN cho mảng lớp, và chỉ mục đồ thị HNSW cho khoảng cách cosine.

Giao diện web (React) có sáu phần: khung tải lên; danh sách bản ghi; dòng thời gian sự kiện (bấm vào sự kiện để nghe đúng đoạn); mô tả song ngữ Anh–Việt kèm bằng chứng; khung hỏi bằng câu tự nhiên, hiển thị bộ lọc đã phân tích dưới dạng thẻ sửa được; và thanh trạng thái mô hình. Bấm vào một trích dẫn trong câu trả lời sẽ mở đúng bản ghi và tua tới đúng khoảng thời gian (Hình 5.1).



Hình 5.1 Giao diện demo: tải lên, dòng thời gian, bộ lọc từ câu hỏi và bằng chứng

Nguồn: docs/demo_screenshots/ (Playwright, 1440×900), ghép bằng scripts/build_thesis_figures.py; bản ghi trong lịch sử demo chỉ lấy từ tập train.

5.3 Chạy demo

Hệ thống chạy cục bộ bằng Docker Compose: một container cơ sở dữ liệu, một container suy luận chạy trên CPU và một container API phục vụ cả giao diện (cổng

8088). Checkpoint và mô hình embedding được gắn vào ở chế độ chỉ đọc; các container đặt chế độ ngoại tuyến nên demo không cần mạng. Mô hình ngôn ngữ chạy trên máy chủ bằng llama.cpp để dùng GPU.

Ba script PowerShell gói các thao tác: khởi động (kiểm Docker, bật llama.cpp, dựng Compose, chờ dịch vụ sẵn sàng và cờ official=true, nạp lịch sử demo), kiểm tra, và dừng. Lịch sử demo gồm 15 bản ghi chọn tự động **chỉ từ tập train** sao cho phủ đủ 21 lớp, để demo không bao giờ phơi bày dữ liệu test. Một lượt kịch bản thật qua API đã chạy năm câu hỏi Anh/Việt (một lớp, hai lớp, quan hệ "trước", thời lượng) và lưu kết quả.

Trên một bản ghi train (S-0016), tải lên và phân tích bằng CPU trong container mất 2,012 s, một truy vấn kết hợp mất 0,250 s. Đây là số đo của một lượt trên một bản ghi, không phải phép đo hiệu năng có thống kê.

Hệ thống có hai giới hạn: chưa có xác thực người dùng nên **không** sẵn sàng triển khai công khai, và dịch vụ xử lý luồng mới chỉ là thư mục khung.

5.4 Tái lập và kiểm thử

Tái lập. Mỗi lần chạy ghi một manifest gồm cấu hình, seed, phiên bản git kèm cờ dirty (cây làm việc có thay đổi chưa commit), mã băm của tập chia, hệ lớp, đặc trưng, tham số ghép sự kiện, và cờ hoàn tất. Lần chạy thiếu một trong các trường này, hoặc chạy trên cây làm việc bẩn, không được dùng cho số chính thức; các trường hợp vi phạm đã xảy ra đều được công khai (Chương 6). Dự đoán thô lưu thành tệp có SHA-256, tách khỏi bước tính chỉ số, nên quét lại ngưỡng trên dev không cần chạy lại mô hình, và tệp dự đoán test chỉ được sinh sau khi lựa chọn đã commit.

Trước khi viết báo cáo, mọi tệp được trích dẫn đã được "đóng băng": một script kiểm sự tồn tại và ghi SHA-256 của 11 lần chạy hoặc ensemble, các checkpoint ngoài và các tệp đầu vào cố định (tập chia, hệ lớp, từ điển, ngữ pháp, bộ truy vấn). Không thiếu tệp nào (Phụ lục B). Tài liệu docs/REPRODUCE.md tách hai quy trình: kiểm toán an toàn chạy trong bản sao hiện tại, và tái tạo số test chỉ làm trong một bản sao mới có

phê duyệt, để không tạo thêm lượt chạm test ngoài sổ ghi. Các bảng số và hình trong báo cáo đều do script sinh từ các tệp trên, ghi rõ tệp nguồn và phiên bản git; chính tệp DOCX này được dựng từ nguồn Markdown bằng một script.

Kiểm thử. Bộ kiểm thử Python dùng pytest, kiểm tra mã bằng ruff. Ở lần kiểm cuối cùng ghi trong báo cáo kiểm tra đi kèm, ruff không báo lỗi và pytest đạt 744 kiểm thử, bỏ qua 4 kiểm thử cần PostgreSQL vì Docker đang tắt. Bộ kiểm thử phủ hợp đồng dữ liệu, ranh giới API–torch, các cổng dữ liệu (kể cả phép thử chứng minh cổng D4 không đạt rỗng), điều kiện thời gian SQL và Python, chỉ số bám sát sự kiện, ba ràng buộc G1–G3, tính trùng từng bit của đường sinh dự đoán, và tích hợp PostgreSQL. CI trên GitHub Actions chạy ruff, pytest, kiểm tra cấm torch trong API, kiểm thử và build giao diện.

Nhiều lỗi thật chỉ bị bắt nhờ chạy toàn bộ quy trình trên dữ liệu thật, trong đó lỗi ghép cửa sổ dự đoán (khoảng 10 s cuối mỗi bản ghi bị nhân đôi) làm đổi mọi số SED đã có; sau khi sửa, toàn bộ 11 lần chạy được tính lại và kết luận RQ1 không đổi.

CHƯƠNG 6 KẾT QUẢ VÀ THẢO LUẬN

Chương này báo cáo các kết quả có được tại mốc giữa kỳ (03/10/2026), kể cả kết quả âm tính và kết quả kém đi. Các bảng do script sinh từ tệp kết quả đã khóa, nguồn ghi ngay dưới bảng. Trong các bảng chính, **số in đậm là giá trị tốt nhất trong cột** (hoặc trong nhóm hàng cùng loại), và **hàng nền xám là cấu hình đang dùng** trong hệ thống cuối; in đậm không có nghĩa là khác biệt có ý nghĩa thống kê. Bốn quy ước khi đọc số:

- **Event-F1** là F1 theo sự kiện với collar 0,2 s (Chương 2), tính bằng thư viện sed_eval; macro hay micro được ghi rõ ở từng chỗ.
- **Tập đánh giá** là all (142 bản ghi test) hoặc annotated (139 bản ghi test có nhãn đa âm, Chương 3).
- **Khoảng tin cậy** 95% được bootstrap theo bản ghi (Chương 4).
- Số trên **dev** dùng để chọn cấu hình; số trên **test** chỉ dùng để đo cấu hình đã chọn và không bao giờ dùng để chọn lại.

6.1 Mô hình phân loại DataSEC

Mô hình phân loại đạt macro-F1 0,8466 trên 22 lớp gộp của tập test DataSEC (Bảng 6.1). Ở cấp lớp con, macro-F1 trên cả 28 nút chỉ là 0,6266 vì bị kéo xuống bởi các nút có rất ít mẫu test; chỉ tính 5 nút có ít nhất 10 mẫu test thì được 0,8453. Theo quy ước, nút ít mẫu chỉ báo số tuyệt đối (Phụ lục C), chẳng hạn vacuum_cleaner đúng 0/4 và air_compressor đúng 0/5. Tỷ lệ nhất quán cha–con là 0,9526: 95% lần, lớp con được đoán thuộc đúng nhóm của lớp gộp được đoán. Hai lớp gộp yếu nhất là vehicle_idling (F1 0,6154) và vehicle_pass_by (0,6538), có âm thanh gần nhau.

Bảng 6.1 Kết quả mô hình phân loại DataSEC trên tập test

Chỉ số	Giá trị	Ghi chú
Macro-F1 lớp gộp (22 lớp)	0.8466	740 đoạn test
Macro-F1 lớp con, mọi nút (28)	0.6266	Gồm cả nút có n_test < 10
Macro-F1 lớp con, nút có n_test ≥ 10 (5)	0.8453	Con số diễn giải được
Tỷ lệ nhất quán cha–con	0.9526	203 đoạn có lớp con
ECE trước hiệu chuẩn (T = 1)	0.033190	Đầu lớp gộp
ECE sau temperature scaling (T = 1.5681, chọn trên dev)	0.056394	Tăng, không giảm

Nguồn: ml/runs/classifier_datasec_20260923T121808Z/metrics.json; docs/measurements/ece_datasec_20260923.md. Bảng sinh tự động bởi script, không sửa tay.

Việc hiệu chuẩn xác suất cho kết quả âm tính: nhiệt độ $T = 1{,}5681$ chọn trên dev làm sai số hiệu chuẩn (ECE) trên test **tăng** từ 0,0332 lên 0,0564. Nhóm báo đúng như vậy, không chỉnh T theo test. Mô hình phân loại tái lập trùng từng bit khi huấn luyện lại cùng seed; mô hình SED thì không (xem phần hạn chế).

6.2 RQ1: học thêm từ DataSEC có giúp không?

Vì huấn luyện SED không tất định (ADR-0021), câu trả lời dựa trên nhiều lần chạy. Với công thức v1 và tập test all, phân tích chính dùng 7 lần chạy có cây làm việc sạch: 3 của nhánh B và 4 của nhánh C (Bảng 6.2). Event-F1 micro trung bình của B là 0,0610 và của C là 0,0539; hiệu C − B (bootstrap ghép cặp theo bản ghi) là −0,0071 [−0,0164; +0,0021], Welch p = 0,2336. PSDS cũng không phân biệt được: PSDS-1 0,2902 so với 0,2892 (p = 0,913), PSDS-2 0,6498 so với 0,6591 (p = 0,181). Phân tích độ nhạy với cả 10 lần chạy cho cùng kết luận (không chỉ số nào có p < 0,05). Ngược lại, tiền huấn luyện nói chung giúp rõ: nhánh A học từ đầu chỉ đạt event-F1 0,0360 và PSDS-2 0,4514, so với 0,0621 và 0,6456 của nhánh B.

Bảng 6.2 Kết quả RQ1: công thức v1 (test all) và công thức v2 (test annotated)

Thí nghiệm	Nhánh	n run	Macro-F1	Micro-F1	95% CI micro	p Welch
RQ1-v1	B	3	—	0.0610	[0.0440, 0.0795]	—
RQ1-v1	C	4	—	0.0539	[0.0391, 0.0699]	—
RQ1-v1	C−B	—	—	-0.0071	[-0.0164, 0.0021]	0.2336
RQ1-v2	B	3	0.1221	0.1324	[0.0985, 0.1681]	—
RQ1-v2	C	3	0.1147	0.1294	[0.0966, 0.1644]	—
RQ1-v2	C−B	—	-0.0074	-0.0029	[-0.0254, 0.0199]	0.6965

Nguồn: docs/measurements/rq1_multiseed_clean_20260924.json; docs/measurements/rq1_multirun_bootstrap_clean_20260925.json; docs/measurements/rq1_v2_multiseed_20260929.json; docs/measurements/rq1_multirun_bootstrap_rq1_v2_annotated_20260929.json. Bảng sinh tự động bởi script, không sửa tay.

Để kiểm tra kết quả âm tính có phải do kiến trúc v1 quá thô, nhóm lặp lại phép so sánh với công thức v2 (3 lần chạy B-v2 so với 3 lần C-v2). Phân tích này được ghi trước và chỉ mở test sau khi hệ thống cuối đã được khóa (ADR-0031). Trên test annotated, event-F1 macro của B-v2 và C-v2 là 0,1221 và 0,1147, micro là 0,1324 và 0,1294. Hiệu C − B về micro là −0,0029 [−0,0254; +0,0199], Welch p = 0,6965 (macro p = 0,4220). Riêng PSDS-2 tăng +0,0279 với p = 0,0193, nên kết luận phụ thuộc vào chỉ số.

Kết luận RQ1: với cả hai công thức, nhóm **không** có bằng chứng rằng huấn luyện thêm trên DataSEC cải thiện event-F1 so với chỉ dùng AudioSet. Điều này không có nghĩa DataSEC "vô ích" nói chung: PSDS-2 của công thức v2 tăng có ý nghĩa khi xét riêng, dù chưa hiệu chỉnh cho việc so sánh nhiều chỉ số. Đây là kết quả âm tính hợp lệ và được giữ nguyên; trọng tâm đóng góp vì vậy chuyển sang C1, C2 và C4 (ADR-0021).

6.3 Mô hình SED tiến bộ ra sao?

6.3.1 Vì sao event-F1 của v1 thấp?

Sau RQ1, event-F1 của v1 còn rất thấp nên nhóm chẩn đoán nguyên nhân trên dev trước khi cải tiến. Một mô hình nhận dạng hoàn hảo nhưng ra quyết định theo khối 0,64 s (như CNN14 nén 64 lần) cũng chỉ đạt tối đa event-F1 0,6294; với khối 1,28 s, tối đa là 0,3032. Giới hạn do nhãn, đo trên 8 cặp bản ghi được gán nhãn hai lần, là

0,5785. Với v1 trên dev, event-F1 nếu chỉ xét thời điểm bắt đầu là 0,2325, chỉ xét thời điểm kết thúc là 0,4975, còn F1 theo đoạn 1 s là 0,6542. Trong 886 sự kiện tham chiếu, 112 khớp collar, 417 đúng lớp và có chồng lấp nhưng lệch biên, và 357 bị bỏ sót. Vậy lỗi chủ yếu nằm ở **biên sự kiện** và **bỏ sót**, không phải nhận dạng lớp. Nới collar thời điểm bắt đầu từ 0,2 s lên 1 s làm event-F1 của nhánh B tăng khoảng ba lần (0,062 lên 0,185), phù hợp với chẩn đoán này.

Các số này là số dev in-sample và hai tệp đo được sinh khi cây làm việc có thay đổi chưa commit (git.dirty = true), nên chỉ dùng để chẩn đoán, không phải kết quả đánh giá. Một giả thuyết ban đầu cho rằng "xác suất bão hòa làm thời điểm bắt đầu bị trễ" đã được đo và bác bỏ (trung vị xác suất của khung không có sự kiện chỉ 0,008; sai số thời điểm bắt đầu phân bố đối xứng, chỉ 30,2% nằm trong ±0,2 s). Chẩn đoán đúng là biên **tản rộng và đối xứng**.

6.3.2 Từ v1 đến v2

Ba lần chạy v2 đạt event-F1 micro theo kiểm chứng chéo trên dev là 0,1900, 0,2096 và 0,2169, so với 0,1538 của ensemble v1. Thử bỏ từng thành phần cho thấy chỉ độ phân giải thời gian có tác động phân biệt được: quay về nén 64 lần làm event-F1 giảm 0,0840, gấp 1,6 lần độ lệch chuẩn giữa các fold. Trần trọng số dương 50 thay cho 10 (−0,0126) và bỏ tăng cường dữ liệu (+0,0068) đều nằm trong nhiễu; mỗi biến thể chỉ có một seed nên "không phân biệt được" không đồng nghĩa "không có tác dụng". Đáng chú ý, average precision theo khung gần như không đổi khi bỏ độ phân giải (0,667 so với 0,688) trong khi event-F1 giảm mạnh: chỉ số theo khung không phản ánh chất lượng định vị.

Theo luật chọn ghi trước, ensemble 3 seed của v2 (kiểm chứng chéo 0,2129 ± 0,0622) được commit trước khi mở test. Nó được chọn theo luật nhưng **không** được gọi là tốt hơn một lần chạy đơn, vì chênh 0,023 nhỏ hơn độ lệch chuẩn giữa các fold. Trên test all, ensemble v2 đạt event-F1 micro 0,1476 [0,1088; 0,1866] và macro 0,1369, so với 0,0941 và 0,0917 của v1; hiệu ghép cặp v2 − v1 là +0,0536 [+0,0261; +0,0853], khoảng tin cậy không chứa 0. Tuy vậy **PSDS không tăng**: PSDS-1 0,3447 so với

0,3489, PSDS-2 0,6744 so với 0,6987. Lợi ích của v2 nằm ở điểm vận hành đã chọn chứ không phải trên toàn dải ngưỡng; nguyên nhân chưa giải thích được và là việc còn lại (Chương 7).

Về ghép sự kiện trên ba nhánh v1: từ dev sang test, event-F1 với ngưỡng riêng từng lớp giảm 48%, 39%, 41% (A, B, C), còn với ngưỡng chung chỉ giảm 15%, 4%, 2%, nên ngưỡng riêng từng lớp quá khớp dev một cách có hệ thống. Lọc trung vị không có tác động rõ (Δ +0,0063, +0,0026, −0,0014; đổi dấu giữa các nhánh).

6.3.3 Chọn hệ thống cuối và kết quả test

Vòng chọn cuối gồm 11 ứng viên đã ghi trước (Chương 4). Các ứng viên được xếp hạng bằng kiểm chứng chéo trên dev annotated, và lựa chọn được commit trước khi sinh dự đoán test cho các ứng viên chưa từng chạm test (commit c3f0033). Hệ f2 (T2b×3 với cSEBB) đứng đầu với event-F1 micro 0,2383 ± 0,0562. Chênh lệch với f4 chỉ 0,0029, nhỏ hơn độ lệch chuẩn của f2, nên f2 được *chọn* theo luật nhưng không được gọi là *tốt hơn* f4 (Bảng 6.3).

Bảng 6.3 Xếp hạng 11 ứng viên trên dev và kết quả test annotated (một lần)

Hạng CV	Mã	Hậu xử lý	Dev micro	SD fold	Test macro	Test micro	95% CI test micro
1	f2	csebb	**0.2383**	0.0562	0.1206	0.1643	[0.1103, 0.2242]
2	f4	theta	0.2354	0.0585	0.1368	0.1543	[0.1163, 0.1912]
3	g2	csebb	0.2319	0.0418	0.1421	0.1722	[0.1232, 0.2218]
4	f1	theta	0.2286	0.0601	0.1521	**0.1817**	[0.1363, 0.2284]
5	d	theta	0.2285	0.0570	0.1161	0.1323	[0.0976, 0.1695]
6	g1	theta	0.2268	0.0547	**0.1617**	0.1774	[0.1337, 0.2260]
7	e	theta	0.2237	0.0665	0.1230	0.1392	[0.1038, 0.1768]
8	c	theta	0.2212	0.0498	0.1389	0.1500	[0.1119, 0.1909]
9	f3	theta	0.2070	0.0560	0.1387	0.1544	[0.1175, 0.1940]
10	b	theta	0.2031	0.0565	0.1211	0.1275	[0.0893, 0.1662]
11	a	theta	0.1620	0.0226	0.0924	0.0945	[0.0639, 0.1258]

Nguồn: docs/measurements/s13_selection_20261018.json; docs/measurements/s13_test_20261018.json. Bảng sinh tự động bởi script, không sửa tay. In đậm: giá trị tốt nhất trong cột (không hàm ý khác biệt có ý nghĩa); nền xám: cấu hình đang dùng.

Trên test annotated, f2 đạt event-F1 macro 0,1206 và micro 0,1643 [0,1103; 0,2242], PSDS-1 0,3164 và PSDS-2 0,7253. Thứ hạng test **không trùng** thứ hạng dev: f1 (BEATs đóng băng) chỉ đứng thứ 4 trên dev nhưng có micro test cao nhất (0,1817);

g1 đứng thứ 6 trên dev nhưng có macro test cao nhất (0,1617). Hệ cuối **không** được chọn lại, vì chọn lại theo test chính là tinh chỉnh trên test. Hơn nữa, khoảng tin cậy test của các ứng viên đứng đầu đều chồng lấp. Đây là minh chứng trực tiếp cho sai số khi chọn mô hình trên tập dev nhỏ (134 bản ghi).

So với các thế hệ trước trên cùng tập test annotated (Bảng 6.4), f2 có micro cao hơn v1 (0,1643 so với 0,0945). So với v2, f2 có micro cao hơn (0,1643 so với 0,1500) nhưng **macro thấp hơn** (0,1206 so với 0,1389) và PSDS-1 thấp hơn (0,3164 so với 0,3458), với khoảng tin cậy micro chồng lấp. Vì vậy báo cáo **không** khẳng định f2 tốt hơn v2: f2 là hệ được khóa theo quy trình, không phải hệ được chứng minh là tốt nhất.

Bảng 6.4 Tiến triển SED v1 → v2 → f2 trên test annotated

Hệ thống	Hậu xử lý	Macro-F1	Micro-F1	95% CI micro	PSDS-1	PSDS-2
v1 — ensemble C	theta	0.0924	0.0945	[0.0639, 0.1258]	**0.3486**	0.6991
v2 — ensemble 3 seed	theta	**0.1389**	0.1500	[0.1119, 0.1909]	0.3458	0.6767
S13 — T2b×3 + cSEBB (khóa)	csebb	0.1206	**0.1643**	[0.1103, 0.2242]	0.3164	**0.7253**

Nguồn: docs/measurements/s13_test_20261018.json. Bảng sinh tự động bởi script, không sửa tay. In đậm: giá trị tốt nhất trong cột (không hàm ý khác biệt có ý nghĩa); nền xám: cấu hình đang dùng.

Phân tích theo lớp (Phụ lục C) cho thấy f2 còn rất yếu: 7/21 lớp có event-F1 bằng 0 trên test, trong đó có vehicle_pass_by (70 sự kiện tham chiếu), birds và dog_barkings_and_howlings. Các lớp tốt nhất là cicadas_and_crickets (0,4138), music (0,3750) và workshop (0,3636); lớp cat_fights_and_moans chỉ có 9 sự kiện tham chiếu nên báo là khớp 1/9. Hệ f2 chỉ dự đoán 295 sự kiện cho 740 sự kiện tham chiếu, và 349 lỗi là bỏ sót: hệ bị giới hạn chủ yếu bởi **recall**.

Về cSEBB. Ở v1, v2 và T2a, cSEBB đều thua ngưỡng chung trên kiểm chứng chéo dev (ví dụ ở v1: 0,0582 so với 0,1538). Hệ f2 là trường hợp đầu tiên cSEBB thắng: 0,2383 ± 0,0562 so với 0,2107 ± 0,0343 của ngưỡng chung, chênh lệch nằm trong biên dao động giữa các fold. Giả thuyết hợp lý là cSEBB phát huy khi xác suất có độ phân giải thật (T2b, 40 ms, không có tầng làm mượt thời gian), còn với mô hình có

tầng hồi quy hoặc gộp thô thì thua. Kết luận về cSEBB vì vậy phải phát biểu có điều kiện, không thể nói chung là "tốt hơn" hay "kém hơn".

6.4 RQ2: mô tả có bám sát sự kiện không?

Bảng 6.5 báo các chỉ số bám sát sự kiện trên test của hệ f2, theo bốn cách sinh và hai mức đánh giá (oracle dùng nhãn gốc, đầu–cuối dùng sự kiện dự đoán). Ba kết quả nổi bật như sau.

Bảng 6.5 Mức bám sát sự kiện của mô tả trên test (hệ f2, 142 bản ghi)

Chế độ	Mức	Ảo giác	Bỏ sót	Thứ tự (n ≥ 2 nhắc)	Quá cụ thể	Bối cảnh	Từ cấm
Template	oracle	**0.0000**	**0.0000**	1.0000 (107)	**0.0000**	**0.0000**	**0.0000**
Template	đầu–cuối	**0.0000**	**0.0000**	1.0000 (63)	**0.0000**	**0.0000**	**0.0000**
Constrained	oracle	**0.0000**	0.0925	1.0000 (99)	**0.0000**	**0.0000**	**0.0000**
Constrained	đầu–cuối	**0.0000**	0.0117	1.0000 (61)	**0.0000**	**0.0000**	**0.0000**
Constrained-cover	oracle	**0.0000**	**0.0000**	1.0000 (107)	**0.0000**	**0.0000**	**0.0000**
Constrained-cover	đầu–cuối	**0.0000**	**0.0000**	1.0000 (63)	**0.0000**	**0.0000**	**0.0000**
Unconstrained	oracle	0.0065	0.0184	0.8475 (73)	0.1388	0.2887	0.0070
Unconstrained	đầu–cuối	0.0112	0.0047	0.8596 (38)	0.1373	0.4014	0.0070

Nguồn: docs/measurements/caption_grounding_sed_ensemble_s13_f2_20260929T045053Z_test.json. Bảng sinh tự động bởi script, không sửa tay. In đậm: giá trị tốt nhất trong cột (không hàm ý khác biệt có ý nghĩa); nền xám: cấu hình đang dùng.

Thứ nhất, khi chỉ nhận danh sách sự kiện, mô hình ngôn ngữ viết tự do **hiếm khi bịa nguồn âm**: tỷ lệ ảo giác của cách unconstrained chỉ 0,0065 (oracle) và 0,0112 (đầu–cuối). Lỗi thật của viết tự do nằm ở chỗ khác: 28,9% (oracle) và 40,1% (đầu–cuối) mô tả thêm bối cảnh không có trong bằng chứng, khoảng 14% gọi tên quá cụ thể so với lớp gộp, và 0,7% chứa từ cấm. Ràng buộc ngữ pháp (constrained và constrained-cover) đưa cả bốn loại lỗi này về 0. Hiệu constrained − unconstrained ở mức đầu–cuối là −0,011 [−0,022; −0,002] với ảo giác và −0,401 [−0,479; −0,324] với bối cảnh.

Thứ hai, ràng buộc có giá: cách constrained **bỏ sót** nhiều hơn. Ở mức oracle, tỷ lệ bỏ sót là 0,0925 so với 0,0184 của unconstrained (hiệu +0,074 [+0,044; +0,107]); ở mức đầu–cuối, hiệu là +0,007 [−0,002; +0,019], khoảng tin cậy chứa 0. Cách constrained-cover giải quyết sự đánh đổi này theo cấu tạo: bỏ sót bằng 0 ở cả hai mức và không thua unconstrained ở chỉ số nào, nhưng văn phong gần với mô tả template.

Thứ ba, khi đổi hệ SED từ v1 sang f2, hướng kết luận giữ nguyên. Bỏ sót đầu–cuối của constrained giảm từ 0,036 xuống 0,012. Ảo giác của unconstrained đổi từ 0,005 thành 0,011 với khoảng tin cậy chồng lấp, nên không phải thay đổi phân biệt được. Mô tả template tiếng Việt trên testkhông vi phạm G1–G3 ở cả hai tập đánh giá. Trong demo, mô tả được sinh bằng template (hàng nền xám).

Hai giới hạn khi đọc kết quả RQ2:

- **Bộ đo dựa trên từ điển.** Trên mẫu 60 mô tả test do **một** người đọc mù đối chiếu (với hệ cũ), việc trích nguồn âm bằng từ điển đạt precision 0,896 và recall 0,936 so với người đọc. Từ điển dễ dãi hơn người ở một số chỗ: một kiểu bịa "tiếng búa gõ" bị che sau từ chỉ địa điểm "xưởng" mà từ điển không bắt được; ở chỗ khác nó gắn cờ nhầm (7/8 lần bị gắn cờ "bịa" trên test hóa ra là lỗi từ điển). Mẫu nhỏ và chỉ một người đọc, nên đây là kiểm tra sơ bộ.
- **"Không ảo giác" ở mức đầu–cuối không có nghĩa là mô tả đúng với âm thanh.** Mô tả trung thành với danh sách sự kiện *dự đoán*, mà hệcó event-F1 micro chỉ 0,1643 và bỏ sót 349/740 sự kiện tham chiếu. Vì vậy phần lớn mô tả đầu–cuối bám sát dự đoán nhưng vẫn thiếu hoặc sai so với âm thanh thật. Ràng buộc bảo đảm mọi sai sót truy được về một sự kiện cụ thể của SED; nó không loại bỏ được sai sót đó.

6.5 RQ3: truy hồi và câu trả lời có bằng chứng

Bảng 6.6 báo kết quả truy hồi trên test cho hai kho sự kiện: kho dựng từ dự đoán của nhánh B (mốc ban đầu) và kho dựng từ dự đoán của hệ f2 (hệ hiện hành), với bộ lọc chuẩn (gold) lấy từ bộ truy vấn. Hàng nền xám là cấu hình của hệ thống: kho f2, chế độ hybrid.

Bảng 6.6 RQ3 trên test với bộ lọc gold: nDCG@10, Recall@10 và độ đúng bộ lọc

Corpus/bộ lọc	Mode/ngôn ngữ	nDCG@10	95% CI	R@10	Filter exactness
Run B — gold	structured_only/en	**0.5231**	[0.4603, 0.5887]	0.5123	**1.0000**
Run B — gold	structured_only/vi	**0.5231**	[0.4603, 0.5887]	0.5123	**1.0000**
Run B — gold	vector_only/en	0.4179	[0.3610, 0.4723]	0.4265	0.5866
Run B — gold	vector_only/vi	0.3403	[0.2911, 0.3914]	0.3409	0.4670
Run B — gold	hybrid/en	0.4808	[0.4236, 0.5386]	0.4865	**1.0000**
Run B — gold	hybrid/vi	0.4716	[0.4124, 0.5301]	0.4974	**1.0000**
f2 — gold	structured_only/en	0.4161	[0.3463, 0.4873]	0.3056	**1.0000**
f2 — gold	structured_only/vi	0.4161	[0.3463, 0.4873]	0.3056	**1.0000**
f2 — gold	vector_only/en	**0.5261**	[0.4669, 0.5824]	0.5027	0.2742
f2 — gold	vector_only/vi	0.4890	[0.4295, 0.5483]	0.4616	0.2629
f2 — gold	hybrid/en	0.4147	[0.3438, 0.4852]	0.3050	**1.0000**
f2 — gold	hybrid/vi	0.4197	[0.3501, 0.4908]	0.3056	**1.0000**

Nguồn: docs/measurements/s8_summary_20261002.json. Bảng sinh tự động bởi script, không sửa tay. In đậm: giá trị tốt nhất trong cột (không hàm ý khác biệt có ý nghĩa); nền xám: cấu hình đang dùng.

Trên kho nhánh B, chế độ structured_only đạt nDCG@10 cao nhất (0,5231), hybrid đứng thứ hai (0,4808 tiếng Anh, 0,4716 tiếng Việt) và vector_only thấp nhất (0,4179 và 0,3403). Hiệu hybrid − structured là −0,042 [−0,085; −0,004]: với tài liệu dạng template, xếp hạng vector trong tập đã lọc không giúp mà còn giảm nhẹ chất lượng. Độ đúng bộ lọc của structured_only và hybrid là 1,000 như kiến trúc yêu cầu; vector_only chỉ đạt 0,5866 (tiếng Anh), tức khoảng 41% kết quả vi phạm ít nhất một ràng buộc cứng của người hỏi.

Khi đổi sang kho f2, kết quả **kém đi** ở hai chế độ có lọc: nDCG@10 của structured_only giảm từ 0,5231 xuống 0,4161, của hybrid (tiếng Anh) từ 0,4808 xuống 0,4147. Ngược lại vector_only tăng từ 0,4179 lên 0,5261. Cách xây tài liệu và cách tính độ liên quan không đổi; thứ thay đổi là tập sự kiện dự đoán. Giả thuyết là f2 dự đoán ít sự kiện hơn hẳn số tham chiếu nên bộ lọc cứng loại mất nhiều bản ghi thực sự liên quan, còn vector_only không bị ràng buộc đó (độ đúng bộ lọc chỉ 0,274)

nên vẫn xếp được các bản ghi này lên. Giả thuyết này **chưa được kiểm chứng**; nhóm báo kết quả kém đi nguyên văn, không diễn giải theo hướng có lợi. Điều này cũng cho thấy chất lượng truy hồi bị chặn bởi recall của SED.

Hai điều kiện đánh giá cần nêu. Thứ nhất, bộ lọc gold giả định câu hỏi luôn được phân tích đúng nên chỉ là cận trên; với bộ lọc do bộ phân tích câu hỏi sinh ra (parsed) trên kho f2, nDCG@10 thay đổi từ −0,006 đến 0,000 so với gold. Thứ hai, ở cả tám cấu hình trả lời (gold/parsed × structured/hybrid × Anh/Việt), tỷ lệ khẳng định thiếu bằng chứng là 0,000 và 97/97 câu trả lời đúng hợp đồng, có bằng chứng thật và trích dẫn thỏa bộ lọc. Câu trả lời không vượt ra ngoài những gì kho chứa; đổi lại, kho thiếu thì câu trả lời cũng thiếu.

6.6 Bộ phân tích câu hỏi và độ khớp khi phục vụ

Bộ phân tích câu hỏi cho đầu ra hợp lược đồ ở 240/240 câu (Bảng 6.7). Độ đúng ngữ nghĩa hoàn toàn đạt 0,855 trên 200 câu template và 0,925 trên 40 câu diễn đạt lại được khóa trước khi chạy. Lỗi chủ yếu nằm ở điều kiện thời gian: độ chính xác trên tập template chỉ 0,767, với các lỗi như đảo vai trò a/b, nhầm "within" thành "overlaps" hoặc bỏ ràng buộc thời lượng. Trên tập validation, hybrid với bộ lọc parsed thay đổi +0,012 (Anh) và −0,002 (Việt) so với gold; mức tăng dương này không phải bằng chứng bộ phân tích cải thiện truy hồi, vì bộ lọc sai cũng có thể tình cờ làm thứ hạng tốt lên.

Bảng 6.7 Đánh giá bộ phân tích câu hỏi thành bộ lọc

Tập	n	Parse success	Exact match	Class precision	Class recall	Predicate accuracy
template	200	1.0000	0.8550	1.0000	1.0000	0.7667
paraphrase	40	1.0000	0.9250	0.9836	1.0000	1.0000

Nguồn: docs/measurements/query_parser_20260928.json. Bảng sinh tự động bởi script, không sửa tay.

Hệ thống phục vụ cũng được kiểm xem có tái tạo đúng đầu ra đã đóng băng không, bằng cách so sự kiện (không chấm điểm lại trên test). Trên GPU, 299/299 sự kiện trùng khít. Trên CPU trong container, phép tính số thực khác nên chỉ 290/299 sự kiện trùng khít và 294/299 nằm trong collar, với sai lệch xác suất lớn nhất 0,0239. Bản

demo chạy CPU nên không hoàn toàn đồng nhất với hệ đã đo; chênh lệch được định lượng như trên.

6.7 Thảo luận và hạn chế

Tóm lại, nhóm đã có một hệ thống đầu–cuối chạy được, cùng bằng chứng cho từng câu hỏi nghiên cứu. RQ1 âm tính với nhiều seed và hai công thức. RQ2 cho thấy ràng buộc ngữ pháp loại bỏ các dạng ảo giác và suy diễn đo được, với cái giá là bỏ sót mà biến thể cover giải quyết. RQ3 cho thấy bộ lọc cứng bảo đảm đúng ràng buộc tuyệt đối, nhưng chất lượng xếp hạng bị chặn bởi chất lượng SED. Điểm yếu nhất hiện nay chính là bước SED: event-F1 và recall thấp truyền xuống mọi tầng sau. Các hạn chế chính:

- **Tập đánh giá nhỏ.** Dev có 137 (134 annotated) và test có 142 (139 annotated) bản ghi, nên khoảng tin cậy rộng. Bootstrap theo bản ghi chỉ phản ánh bất định do mẫu bản ghi, không phản ánh dao động giữa các seed.
- **Huấn luyện SED không tất định.** Cùng mã và cùng seed, F1 macro theo khung của nhánh B vẫn đổi từ 0,5850 sang 0,5705; mọi so sánh SED cần nhiều seed, trong khi các thử nghiệm bỏ-từng-phần của v2 chỉ có một seed.
- **Giới hạn của nhãn.** Giới hạn người đo trên chỉ 8 cặp; collar 0,2 s chặt hơn độ chính xác của nhãn.
- **Micro và macro.** Trước ngày 26/09 các số chính đều là micro, lệch với quy tắc báo macro. Từ ngày này macro được báo trước nhưng việc chọn hệ thống vẫn dùng micro, nên f2 có macro test thấp hơn v2.
- **Sai lệch truy nguồn.** Ở vòng chọn cuối, lượt đánh giá test đầu chạy trên cây làm việc sạch, nhưng báo cáo chưa commit do chính script sinh ra làm 15 lượt sau ghi dirty; mẫu hình này lặp lại ở S8 với một thư mục log tạm. Mã và cấu hình không đổi và test không chạy lại, nhưng đây vẫn là hạn chế truy nguồn cần công khai. Sổ ghi test (Phụ lục B) cho thấy 10/40 lượt đánh giá SED có cờ dirty.
- **Trùng nguồn với AudioSet** (mức trùng không định lượng được) và **chưa có mốc so sánh công bố** trên DataSED; số của DCASE 2016 chỉ để định cỡ.
- **Bộ đo mô tả dựa trên từ điển**, chỉ đối chiếu với một người đọc trên 60 mô tả.

- **Kết quả RQ3 với bộ lọc gold** chỉ là cận trên về độ đúng bộ lọc.
- **PSDS không tăng** dù event-F1 tăng (v2 so với v1), nguyên nhân chưa giải thích được.

CHƯƠNG 7 TIẾN ĐỘ VÀ KẾ HOẠCH TIẾP THEO

7.1 Tiến độ so với kế hoạch

Đề tài bắt đầu ngày 22/09/2026 với kế hoạch tám tuần, hạn nộp 09/11/2026 và một tuần dự phòng tới 16/11/2026. Kế hoạch gốc xếp công việc theo thứ tự phụ thuộc: kiểm tra dữ liệu, mô hình phân loại, SED, chỉ số đánh giá, sinh mô tả, truy hồi, ứng dụng, cuối cùng là viết báo cáo. Bảng 7.1 đối chiếu kế hoạch với thực tế tại mốc 03/10/2026.

Bảng 7.1 Kế hoạch và tiến độ thực tế tại mốc 03/10/2026

Hạng mục	Kế hoạch	Thực tế	Trạng thái
Dữ liệu D0–D4, tập chia đóng băng	22–28/09	Xong 23/09	Đã kiểm chứng
Mô hình phân loại DataSEC	29/09–05/10	Xong 23/09	Đã kiểm chứng
SED ba nhánh, chỉ số, phân tích lỗi (W3–W4)	06–19/10	Xong 24–26/09; RQ1 nhiều seed	Đã kiểm chứng
Cải tiến SED (v2, Track 2, chọn hệ cuối)	Thêm 26/09; khóa mô hình 18/10	v2 chốt 26/09; khóa f2 ngày 29/09	Đã kiểm chứng
Mô tả bám sát sự kiện (RQ2)	20–26/10	Xong 25–26/09; chạy lại trên f2 ngày 02/10	Đã kiểm chứng
Kho sự kiện, RAG, truy hồi (RQ3)	27/10–02/11	Xong 26/09; bộ phân tích câu hỏi 28/09; chạy lại trên f2 ngày 02/10	Đã kiểm chứng
API, giao diện, demo, đóng băng tệp kết quả	03–09/11	Xong 02/10	Đã kiểm chứng
Viết báo cáo khóa luận	19/10–09/11	Báo cáo giữa kỳ này	Đang thực hiện
Slide bảo vệ	03–09/11	Chưa bắt đầu	Chưa thực hiện

Nguồn: docs/PLAN.md (bảng trạng thái tổng, khối Lộ trình tới hạn nộp); CLAUDE.md §10.

Phần kỹ thuật đi trước lịch vì các hạng mục không phụ thuộc nhau được làm song song và các thí nghiệm dài chạy theo hàng đợi ngoài giờ. Việc đi trước lịch không làm đổi kỷ luật đánh giá: mốc khóa mô hình dự kiến 18/10 được thực hiện sớm vào 29/09 khi mọi ứng viên ghi trước đã có đủ kết quả trên dev (ADR-0031), luật chọn vẫn ghi trước và lựa chọn vẫn commit trước khi mở test. Có ba hạng mục phát sinh ngoài kế hoạch gốc, đều do số đo chỉ ra: giai đoạn cải tiến SED (sau khi đo được giới

hạn trên của v1), tập đánh giá annotated (sau khi phát hiện 14 bản ghi thiếu nhãn đa âm), và bộ phân tích câu hỏi thành bộ lọc (để giao diện nhận câu hỏi tự nhiên).

7.2 Mức độ đạt mục tiêu

Đối chiếu với bảy việc nêu ở Chương 1:

- **Đã đạt và có bằng chứng: các việc (1), (2), (4), (5), (6), (7).** Quy trình dữ liệu có đủ nguồn gốc, các cổng kiểm tra đạt và tập chia khóa bằng mã băm; mô hình phân loại đạt macro-F1 0,8466; phép đo chuyển giao đã làm với nhiều seed (kết quả âm tính); bộ sinh mô tả có ràng buộc kiểm thử tự động cùng chỉ số ảo giác có khoảng tin cậy; truy hồi kết hợp có điều kiện thời gian và ba cấu hình so sánh được; ứng dụng web chạy đầu–cuối với kịch bản demo đã chạy thật.
- **Đạt về quy trình nhưng chất lượng còn thấp: việc (3), mô hình SED.** SED được đánh giá đúng chuẩn (event-F1 và PSDS), nhưng hệ khóa chỉ đạt event-F1 macro 0,1206 và micro 0,1643 trên test annotated, thấp so với giới hạn độ phân giải và giới hạn người đã đo.

Về ba câu hỏi nghiên cứu, cả ba đã có câu trả lời có bằng chứng:

- **RQ1:** âm tính về event-F1 với cả hai công thức huấn luyện.
- **RQ2:** ràng buộc ngữ pháp đưa ảo giác, suy diễn bối cảnh, gọi tên quá cụ thể và từ cấm về 0; cái giá là bỏ sót, và biến thể cover khử được cái giá này.
- **RQ3:** bộ lọc cứng bảo đảm đúng ràng buộc tuyệt đối nhưng xếp hạng bị chặn bởi chất lượng SED; khi đổi sang kho f2, các chế độ có lọc kém đi.

Mức khẳng định đóng góp giữ thận trọng như ở Chương 1: C1–C4 có bằng chứng thực nghiệm trong phạm vi đề tài, nhưng tính mới so với văn liệu chưa được khẳng định.

7.3 Hạn chế

Các hạn chế về chất lượng SED, tập đánh giá nhỏ, tính không tất định, bộ đo dựa trên từ điển và sai lệch truy nguồn đã nêu ở Chương 6. Ngoài ra có hai hạn chế về phạm vi: nhóm mới đọc trực tiếp 14 nguồn, chưa tổng quan các mảng mô tả âm thanh tự động, truy hồi âm thanh và kiểm soát trùng lặp khi học chuyển giao, nên chưa có cơ

sở khẳng định tính mới; và hệ thống chưa sẵn sàng triển khai thật (chưa có xác thực, chưa xử lý luồng, bản demo chạy CPU không trùng khít hoàn toàn với hệ đã đo).

7.4 Kế hoạch giai đoạn tiếp theo

Từ sau báo cáo giữa kỳ đến hạn nộp 09/11/2026, nhóm ưu tiên hoàn thiện báo cáo cuối và bổ sung các phân tích làm rõ kết quả hiện có. Nhóm **không** mở rộng phạm vi và **không** chạy thêm đánh giá trên test cho hệ đã khóa (Bảng 7.2).

Bảng 7.2 Kế hoạch giai đoạn tiếp theo

Thời gian	Công việc	Kết quả nghiệm thu
04–12/10	Nhận nhận xét giữa kỳ của giảng viên hướng dẫn; điều chỉnh đề cương báo cáo cuối	Danh sách chỉnh sửa có xác nhận
04–18/10	Khảo sát văn liệu có hệ thống (mô tả âm thanh tự động và ảo giác, truy hồi âm thanh, kiểm soát trùng lặp giữa các bộ dữ liệu, baseline trên DataSED)	Ba nhận định về tính mới được xác nhận hoặc rút lại
06–18/10	Giải thích vì sao PSDS không tăng khi event-F1 tăng, **chỉ trên dev**; phân tích tương quan lỗi giữa các họ mô hình trong ensemble	Báo cáo đo sinh bằng script
06–18/10	Mở rộng kiểm tra bộ đo mô tả: thêm người đọc, mẫu lớn hơn nếu kịp	Độ đồng thuận từ điển–người có khoảng tin cậy hẹp hơn
19/10–02/11	Viết báo cáo cuối kỳ hoàn chỉnh; duyệt cụm từ tiếng Việt của giao diện	Bản thảo đầy đủ gửi giảng viên
03–09/11	Hoàn thiện định dạng, slide bảo vệ, tập dượt demo	Bản nộp và slide
10–16/11	Dự phòng, chỉ dùng khi được gia hạn	—

Nguồn: docs/PLAN.md (L3–L6, nợ kỹ thuật #5, #6, #11); docs/PAPER_NOTES.md §6.

Các hướng dài hạn — tổng hợp âm thanh nền từ đoạn DataSEC để tạo nhãn mạnh cho lớp hiếm, huấn luyện chung nhãn mạnh và nhãn yếu, xử lý luồng thời gian thực, dữ liệu đa kênh — được ghi nhận nhưng **không** thuộc phạm vi khóa luận.

7.5 Kết luận giữa kỳ

Tại thời điểm giữa kỳ, nhóm đã xây xong một hệ thống đầu–cuối tái lập được: từ dữ liệu công bố, qua phát hiện sự kiện và sinh mô tả bám sát sự kiện, đến truy vấn có trích dẫn. Mỗi tầng đều có phép đo, và mọi phép đo theo quy tắc chọn trên dev, kiểm tra một lần. Điều quan trọng nhất không phải một con số cao, mà là hệ thống *biết và đo được* giới hạn của mình:

- hai bộ dữ liệu có chung bản ghi gốc, và mức trùng đã được định lượng;
- huấn luyện thêm trên DataSEC không cải thiện SED;
- lỗi SED nằm ở biên sự kiện và ở bỏ sót;
- ràng buộc giải mã loại bỏ suy diễn với cái giá đo được;
- truy hồi bị chặn bởi recall của SED.

Giai đoạn tiếp theo tập trung làm rõ các kết quả này bằng phân tích trên dev và tổng quan văn liệu có hệ thống, rồi hoàn thiện báo cáo cuối đúng hạn.

TÀI LIỆU THAM KHẢO

Tiếng Anh

[1]. Çağdaş Bilen, Giacomo Ferroni, Francesco Tuveri, Juan Azcarreta, Sacha Krstulović (2020), "A Framework for the Robust Evaluation of Sound Event Detection", *Proceedings of the 2020 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*, pp. 61–65, DOI: 10.1109/ICASSP40776.2020.9052995.

[2]. Jianlyu Chen, Shitao Xiao, Peitian Zhang, Kun Luo, Defu Lian, Zheng Liu (2024), "M3-Embedding: Multi-Linguality, Multi-Functionality, Multi-Granularity Text Embeddings Through Self-Knowledge Distillation", *Findings of the Association for Computational Linguistics: ACL 2024*, pp. 2318–2335, DOI: 10.18653/v1/2024.findings-acl.137.

[3]. Sanyuan Chen, Yu Wu, Chengyi Wang, Shujie Liu, Daniel Tompkins, Zhuo Chen, Furu Wei (2022), "BEATs: Audio Pre-Training with Acoustic Tokenizers", *arXiv preprint* arXiv:2212.09058v1.

[4]. DCASE Community (2016), *DCASE 2016 Task 3: Sound Event Detection in Real Life Audio*, Trang nhiệm vụ và trang kết quả DCASE Challenge 2016, https://dcase.community/challenge2016/task-sound-event-detection-in-real-life-audio, truy cập 27/09/2026.

[5]. Janek Ebbers, François G. Germain, Gordon Wichern, Jonathan Le Roux (2024), "Sound Event Bounding Boxes", *Proceedings of Interspeech 2024*, pp. 562–566, DOI: 10.21437/Interspeech.2024-2075.

[6]. Luca Fredianelli, Francesco Artuso, Geremia Pompei, Gaetano Licitra, Gino Iannace, Andac Akbaba (2025), "Environmental Noise Dataset for Sound Event Classification and Detection", *Scientific Data*, Vol. 12, Article 1712, DOI: 10.1038/s41597-025-05991-w.

[7]. Ziwei Ji, Nayeon Lee, Rita Frieske, Tiezheng Yu, Dan Su, Yan Xu, Etsuko Ishii, Ye Jin Bang, Andrea Madotto, Pascale Fung (2023), "Survey of Hallucination in Natural Language Generation", *ACM Computing Surveys*, Vol. 55 (12), pp. 1–38, DOI: 10.1145/3571730.

[8]. Qiuqiang Kong, Yin Cao, Turab Iqbal, Yuxuan Wang, Wenwu Wang, Mark D. Plumbley (2020), "PANNs: Large-Scale Pretrained Audio Neural Networks for Audio Pattern Recognition", *IEEE/ACM Transactions on Audio, Speech, and*

Language Processing, Vol. 28, pp. 2880–2894, DOI: 10.1109/TASLP.2020.3030497.

[9]. Patrick Lewis, Ethan Perez, Aleksandra Piktus, Fabio Petroni, Vladimir Karpukhin, Naman Goyal, Heinrich Küttler, Mike Lewis, Wen-tau Yih, Tim Rocktäschel, Sebastian Riedel, Douwe Kiela (2020), "Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks", *arXiv preprint* arXiv:2005.11401v4.

[10]. Annamaria Mesaros, Toni Heittola, Tuomas Virtanen (2016), "Metrics for Polyphonic Sound Event Detection", *Applied Sciences*, Vol. 6 (6), Article 162, DOI: 10.3390/app6060162.

[11]. Annamaria Mesaros, Toni Heittola, Tuomas Virtanen, Mark D. Plumbley (2021), "Sound Event Detection: A Tutorial", *IEEE Signal Processing Magazine*, Vol. 38 (5), pp. 67–83, DOI: 10.1109/MSP.2021.3090678.

[12]. Hyeonuk Nam, Seong-Hu Kim, Yong-Hwa Park (2022), "FilterAugment: An Acoustic Environmental Data Augmentation Method", *Proceedings of the 2022 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*, pp. 4308–4312, DOI: 10.1109/ICASSP43922.2022.9747680.

[13]. Florian Schmid, Tobias Morocutti, Francesco Foscarin, Jan Schlüter, Paul Primus, Gerhard Widmer (2025), "Effective Pre-Training of Audio Transformers for Sound Event Detection", *Proceedings of the 2025 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*, pp. 1–5, DOI: 10.1109/ICASSP49660.2025.10888942.

[14]. Hongyi Zhang, Moustapha Cisse, Yann N. Dauphin, David Lopez-Paz (2018), "mixup: Beyond Empirical Risk Minimization", *Proceedings of the 6th International Conference on Learning Representations (ICLR 2018)*.

PHỤ LỤC

Phụ lục A. Hệ lớp và số sự kiện đa âm

Bảng dưới liệt kê 22 lớp của hệ lớp phiên bản 0.1, nhãn gốc tương ứng, các lớp con chỉ có trên DataSEC, và số sự kiện trong bản nhãn đa âm của DataSED (toàn bộ ba tập). Lớp wind_turbine không thuộc 21 lớp của mô hình SED.

Bảng PL.1 Hệ lớp phiên bản 0.1

class_id	Nhãn gốc	Lớp con (DataSEC)	Thuộc SED 21 lớp	Sự kiện đa âm DataSED
bells	Bells	—	có	116
birds	Birds	—	có	267
cat_fights_and_moans	Cat fight and moans	—	có	138
chicken_coop	Chicken coop	—	có	166
cicadas_and_crickets	Cicadas and crickets	cicadas, crickets	có	419
crows_seagulls_magpies	Crows seagulls and magpies	crows, seagulls, magpies	có	160
dog_barkings_and_howlings	Dog barkings and howlings	—	có	271
glass_breaking	Glass breaking	—	có	120
horn	Horn	—	có	139
jet_aircrafts	Jet aircrafts	—	có	87
lawn_mower_brush_cutter_olive_shaker	Lawn mower brush cutter and olive shaker	lawn_mower, brush_cutter, olive_shaker	có	135
music	Music	—	có	142
propeller_aircrafts	Propeller aircrafts	airplanes, helicopters	có	125
sirens_and_alarms	Sirens and alarms	sirens, alarms	có	129
thunder_fireworks_gunshot	Thunder fireworks and gunshot	thunder, fireworks, gunshot	có	129
train	Train	—	có	133
vacuum_cleaner_fan_hairdryer	Vacuum cleaner fan and hairdryer	vacuum_cleaner, fan, hairdryer	có	133
vehicle_idling	Vehicle idling	car_truck_idling, motorbike_idling	có	152
vehicle_pass_by	Vehicle pass-by	car_pass_by, motorbike_pass_by, truck_pass_by	có	287
voices	Voices	—	có	359

class_id	Nhãn gốc	Lớp con (DataSEC)	Thuộc SED 21 lớp	Sự kiện đa âm DataSED
wind_turbine	Wind turbine	—	không	0
workshop	Workshop	air_compressor, drill, grinder, jackhammer, saw	có	427

Nguồn: ml/configs/taxonomy.yaml; data/annotations/datased_polyphonic_events.csv. Bảng sinh tự động bởi script, không sửa tay.

Phụ lục B. Artifact đã đóng băng

Mọi run, ensemble và checkpoint ngoài được trích trong báo cáo đã được kiểm sự tồn tại và ghi SHA-256 ngày 02/10/2026 bằng scripts.freeze_artifacts. Danh sách đầy đủ của 11 lần chạy hoặc ensemble, các checkpoint ngoài và các tệp đầu vào cố định, kèm SHA-256 từng tệp, nằm ở docs/measurements/artifact_freeze_20261002.md; không thiếu tệp nào.

Bảng dưới là sổ ghi mọi lần chạm tập test tính đến mốc báo cáo, sinh tự động từ các tệp kết quả đã khóa.

Bảng PL.2 Sổ ghi các lần chạm tập test tính đến mốc báo cáo

Nhóm	Số mục
Đánh giá SED trên test	40
Caption (RQ2)	16
Caption: lớp gộp / wiring	5
Retrieval (RQ3) / câu trả lời	6
Ablation / chẩn đoán SED trên test	13
Classifier DataSEC	2
Parity phục vụ (so với output đóng băng)	6
Đánh giá SED ghi git dirty	10

Nguồn: docs/measurements/test_ledger_20261002.json. Bảng sinh tự động bởi script, không sửa tay.

Phụ lục C. Kết quả theo lớp

Theo giao thức đánh giá, lớp có dưới 10 mẫu test chỉ được báo bằng số tuyệt đối. Bảng đầu là mô hình phân loại DataSEC ở cấp lớp gộp; bảng sau là hệ SED f2 trên test annotated. Ở bảng sau, số sự kiện tham chiếu được đếm từ nhãn gốc, còn F1, precision và recall đọc từ tệp đánh giá đã lưu, không chạy lại đánh giá.

Bảng PL.3 Mô hình phân loại DataSEC theo lớp gộp (test)

Lớp	Đúng / tổng	F1
bells	9/10	0.7826
birds	11/11	0.9565
cat_fights_and_moans	5/7	— (n < 10)
chicken_coop	9/9	— (n < 10)
cicadas_and_crickets	11/11	1.0000
crows_seagulls_magpies	16/16	0.9697
dog_barkings_and_howlings	9/10	0.9474
glass_breaking	12/13	0.8276
horn	7/8	— (n < 10)
jet_aircrafts	14/15	0.8750
lawn_mower_brush_cutter_olive_shaker	11/14	0.7097
music	135/145	0.9507
propeller_aircrafts	15/16	0.8824
sirens_and_alarms	14/15	0.9333
thunder_fireworks_gunshot	32/35	0.9014
train	8/9	— (n < 10)
vacuum_cleaner_fan_hairdryer	8/14	0.6957
vehicle_idling	12/16	0.6154
vehicle_pass_by	17/33	0.6538
voices	277/285	0.9840
wind_turbine	15/15	1.0000
workshop	29/33	0.8923

Nguồn: docs/measurements/per_class_metrics_datasec_20260923.md. Bảng sinh tự động bởi script, không sửa tay.

Bảng PL.4 Event-F1 theo lớp của hệ f2 trên test annotated

Lớp	Sự kiện tham chiếu	F1	Precision	Recall
bells	28	0.1364	0.1875	0.1071
birds	29	0.0000	0.0000	0.0000
cat_fights_and_moans	9	khớp 1/9	—	—
chicken_coop	34	0.0513	0.2000	0.0294
cicadas_and_crickets	70	0.4138	0.5217	0.3429
crows_seagulls_magpies	24	0.0000	0.0000	0.0000
dog_barkings_and_howlings	39	0.0000	0.0000	0.0000
glass_breaking	31	0.2593	0.3043	0.2258
horn	30	0.1111	0.3333	0.0667
jet_aircrafts	15	0.0000	0.0000	0.0000
lawn_mower_brush_cutter_olive_shaker	35	0.0930	0.2500	0.0571
music	36	0.3750	0.4286	0.3333

Lớp	Sự kiện tham chiếu	F1	Precision	Recall
propeller_aircrafts	26	0.0952	0.1250	0.0769
sirens_and_alarms	25	0.1538	0.2143	0.1200
thunder_fireworks_gunshot	32	0.0000	0.0000	0.0000
train	28	0.0952	0.1429	0.0714
vacuum_cleaner_fan_hairdryer	17	0.1143	0.1111	0.1176
vehicle_idling	33	0.0000	0.0000	0.0000
vehicle_pass_by	70	0.0000	0.0000	0.0000
voices	60	0.1039	0.2353	0.0667
workshop	69	0.3636	0.4878	0.2899

Nguồn: ml/runs/sed_ensemble_s13_f2_20260929T045053Z/evaluation_cv_annotated.json; data/annotations/datased_polyphonic_events.csv; data/splits/datased_polyphonic.csv; data/manifests/datased_polyphonic_unannotated.csv. Bảng sinh tự động bởi script, không sửa tay.

NHẬT KÍ LÀM VIỆC

Đề tài: Xây dựng hệ thống phát hiện, sinh mô tả và truy vấn sự kiện âm thanh môi trường dựa trên RAG

Giảng viên hướng dẫn: TS. Huỳnh Công Bằng

Ngày bắt đầu: 22/09/2026

Tuần	Từ ngày	Đến ngày	Ngày báo cáo GVHD	Tóm tắt công việc đã thực hiện	Nhận xét của GVHD
1	22/09/2026	28/09/2026	04/10/2026	Kiểm chứng tệp nén, kiểm kê, khử trùng lặp nội bộ và xuyên dataset, đóng băng tập chia; mô hình phân loại DataSEC; SED ba nhánh và RQ1 nhiều seed; metric event-F1/PSDS; mô tả có căn cứ (RQ2); kho sự kiện và truy hồi (RQ3); chẩn đoán và chốt SED v2; dịch vụ suy luận, API, giao diện; Track 2a; bộ phân tích câu hỏi	
2	29/09/2026	03/10/2026	04/10/2026	Focal loss (S11); vòng chọn cuối S13 khóa f2 và test một lần; RQ1-v2; chạy lại RQ2/RQ3 trên f2 (S8); hoàn thiện demo, đóng băng artifact, tài liệu tái lập; báo cáo giữa kỳ	
3	04/10/2026	10/10/2026		(chưa diễn ra)	
4	11/10/2026	17/10/2026		(chưa diễn ra)	
5	18/10/2026	24/10/2026		(chưa diễn ra)	
6	25/10/2026	31/10/2026		(chưa diễn ra)	
7	01/11/2026	07/11/2026		(chưa diễn ra)	
8	08/11/2026	14/11/2026		(chưa diễn ra)	